ĐỀ BÀI, HƯỚNG DẪN & TIÊU CHÍ CHẤM ĐIỂM (RUBRIC) BÀI TẬP LỚN MÔN HỌC MÁY

- **Học phần:** Học máy (Machine Learning) - Mã HP: 608807
- **Khoa:** Công nghệ Thông tin - Trường Đại học Xây dựng Hà Nội (HUCE)
- **Hình thức:** Làm việc theo nhóm (3 - 5 sinh viên/nhóm tùy quy mô lớp)

I. MỤC TIÊU & CHUẨN ĐẦU RA CỦA BÀI TẬP LỚN

Bài tập lớn là hoạt động tổng hợp kiến thức thực tiễn quan trọng nhất trong học phần, trực tiếp đánh giá và đóng góp vào các Chuẩn đầu ra học phần (Course Learning Outcomes - CLO) theo Đề cương chi tiết của Nhà trường:

- **CLO2:** Lựa chọn và giải thích được lý do lựa chọn thuật toán học máy phù hợp với bài toán thực tế đặt ra.
- **CLO3:** Vận dụng được các thư viện Python (Scikit-learn, Pandas, NumPy, Matplotlib/Seaborn) để tiền xử lý dữ liệu, xây dựng Pipeline học máy, đánh giá và tối ưu hóa mô hình.
- **CLO4:** Tham gia tích cực vào hoạt động nhóm, tuân thủ đạo đức chuyên môn khoa học dữ liệu (không ngụy tạo kết quả, trích dẫn nguồn dữ liệu minh bạch), kỹ năng trình bày báo cáo kỹ thuật và thuyết trình bảo vệ dự án.

II. ĐỀ BÀI & YÊU CẦU DỰ ÁN

1. Đề tài chung:

Mỗi nhóm sinh viên lựa chọn **01 bài toán thực tế** (thuộc danh sách gợi ý tại Mục V hoặc nhóm tự đề xuất và được Giảng viên phê duyệt). Nhóm phải triển khai một **Quy trình Học máy Hoàn chỉnh từ đầu đến cuối (End-to-End Machine Learning Workflow)** bao gồm:

1. **Khám phá và Tiền xử lý dữ liệu (EDA & Data Preprocessing):** Thu thập/tải dữ liệu, làm sạch, xử lý khuyết thiếu, xử lý ngoại lai, phân tích tương quan, chuẩn hóa và mã hóa đặc trưng.
2. **Kỹ nghệ đặc trưng (Feature Engineering):** Tạo thêm thuộc tính có ý nghĩa từ dữ liệu gốc, phân tích mức độ quan trọng của đặc trưng.
3. **Thử nghiệm Đa mô hình (Multi-Model Experimentation):** Triển khai ít nhất **03 dòng thuật toán học máy khác nhau** (ví dụ: mô hình tuyến tính Linear/Logistic, mô hình lân cận k-NN, mô hình cây Decision Tree, mô hình tập hợp Random Forest / Boosting).
4. **Đóng gói Pipeline & Chống Rò rỉ Dữ liệu:** Sử dụng `Pipeline` và `ColumnTransformer` của Scikit-learn để đảm bảo tính toàn vẹn của dữ liệu trong quá trình huấn luyện và kiểm thử.
5. **Đánh giá Chéo & Tinh chỉnh Siêu tham số:** Thực hiện K-Fold Cross Validation và tối ưu siêu tham số bằng `GridSearchCV` hoặc `RandomizedSearchCV`.

6. **Đánh giá Chuyên sâu & Phân tích Lỗi (Error Analysis):** Lập bảng so sánh định lượng đa chỉ số (không chỉ dựa vào Accuracy), phân tích ma trận nhầm lẫn hoặc biểu đồ phần dư, giải thích tại sao mô hình tối ưu lại vượt trội.
7. **Đóng gói Sản phẩm & Suy luận (Deployment Prototype):** Lưu trữ mô hình tối ưu ra định dạng file `.joblib` và viết hàm dự đoán cho dữ liệu mới.

---

2. Yêu cầu Sản phẩm Nộp (Deliverables):

Mỗi nhóm phải nộp đầy đủ gói hồ sơ gồm 4 thành phần sau vào thư mục lưu trữ của lớp:

```
[Tên_Nhom]_[Mã_Lớp]_[Tên_Đề_Tài]/
├── 01_Report/
|   └── Bao_cao_BTL_[Tên_Nhom].pdf         # File Báo cáo kỹ thuật (15 - 25 trang)
├── 02_Slide/
|   └── Slide_Thuyet_trinh_[Tên_Nhom].pdf   # Slide thuyết trình (12 - 15 trang)
├── 03_SourceCode/
|   ├── data/                               # Dữ liệu gốc hoặc file mô tả tải dữ
liệu
|   ├── notebooks/
|   |   ├── 01_EDA_Preprocessing.ipynb      # Notebook phân tích dữ liệu & tiền xử
lý
|   |   └── 02_Modeling_Evaluation.ipynb    # Notebook huấn luyện, tuning & so
sánh mô hình
|   ├── models/
|   |   └── best_model.joblib               # Mô hình tối ưu nhất đã được xuất bản
|   ├── predict.py                          # Script nhận diện / suy luận mẫu dữ
liệu mới
|   ├── requirements.txt                    # Danh sách thư viện và phiên bản
chính xác
|   └── README.md                           # Hướng dẫn cài đặt và chạy thử mã
nguồn
└── 04_Video_Demo/ (Khuyến khích)           # Video ngắn 3 phút chạy demo dự
phòng
```

Chi tiết Quy cách Báo cáo Kỹ thuật (Technical Report):

- **Độ dài:** Từ 15 đến 25 trang A4 (không kể phụ lục và tài liệu tham khảo), font chữ Times New Roman cỡ 13, giãn dòng 1.3 - 1.5.
- **Cấu trúc bắt buộc:**
  - **Trang bìa & Bảng phân công công việc:** Nêu rõ họ tên, mã sinh viên, vai trò trong nhóm và **tỷ lệ đóng góp (%)** của từng thành viên có chữ ký xác nhận của cả nhóm.
  - **Chương 1: Giới thiệu bài toán & Mục tiêu nghiên cứu:** Ý nghĩa thực tiễn, định nghĩa biến độc lập (X) và biến mục tiêu (y).
  - **Chương 2: Khám phá Dữ liệu (EDA) & Tiền xử lý:** Biểu đồ phân phối, tương quan, chiến lược xử lý missing values, outliers, encoding và chuẩn hóa.
  - **Chương 3: Cơ sở Thuật toán & Thiết kế Pipeline:** Trình bày tóm tắt nguyên lý toán học của các thuật toán được thử nghiệm và sơ đồ luồng dữ liệu Pipeline.

- **Chương 4: Kết quả Thực nghiệm & Đánh giá Mô hình:** Bảng so sánh chỉ số đánh giá, kết quả Cross-validation, biểu đồ ROC-AUC / Residual Plot, phân tích Feature Importance.
- **Chương 5: Kết luận & Hướng phát triển:** Điểm mạnh, hạn chế của giải pháp và khả năng ứng dụng thực tế.
- **Tài liệu tham khảo:** Trích dẫn các bài báo khoa học, trang web lưu trữ dữ liệu chính thức.

III. TIÊU CHÍ ĐÁNH GIÁ CHI TIẾT (RUBRIC)

Điểm Bài tập lớn được đánh giá theo **Thang điểm 10**, gắn trực tiếp với các chuẩn đầu ra CLO của học phần:

Tiêu chí	Trọng số	Chuẩn đầu ra (CLO)	Mức 1: Kém (0% - 49%)	Mức 2: Đạt (50% - 69%)	Mức 3: Khá - Tốt (70% - 84%)	Mức 4: Xuất sắc (85% - 100%)
1. Khám phá & Tiền xử lý dữ liệu	**20%** (2.0 đ)	**CLO3**	Bỏ qua EDA hoặc xử lý dữ liệu sơ sài; phạm lỗi rò rỉ dữ liệu (Data Leakage) nghiêm trọng.	Có làm sạch dữ liệu cơ bản (bỏ dòng null), có biểu đồ phân tích đơn giản nhưng chưa có nhận xét sâu sắc.	EDA chi tiết với nhiều đồ thị phong phú; xử lý đầy đủ missing values, encoding, scaling bằng `ColumnTransformer`.	Tiền xử lý xuất sắc; có kỹ nghệ đặc trưng (Feature Engineering) độc đáo; xử lý ngoại lai thông minh; code tối ưu, sạch sẽ.
2. Kiến trúc Pipeline & Thử nghiệm mô hình	**25%** (2.5 đ)	**CLO2, CLO3**	Thử nghiệm dưới 3 mô hình; code rời rạc, chạy thủ công từng khối; không sử dụng Scikit-learn Pipeline.	Thử nghiệm đủ 3 mô hình nhưng thiếu mô hình Baseline; chưa tích hợp toàn diện vào `Pipeline`.	Thử nghiệm ≥ 3 dòng thuật toán khác nhau; đóng gói toàn bộ luồng xử lý và mô hình vào `Pipeline` chuẩn mực.	Thử nghiệm đa dạng thuật toán từ tuyến tính đến Ensemble; Pipeline tự động hóa hoàn toàn; code đạt chuẩn công nghiệp.
3. Đánh giá chéo & Tinh chỉnh siêu tham số	**20%** (2.0 đ)	**CLO2, CLO3**	Không thực hiện Cross-Validation; chỉ chia train/test đơn lẻ; chọn	Có chạy K-Fold nhưng áp dụng sai quy trình (để lộ dữ liệu); tinh chỉnh	Thực hiện đúng K-Fold / Stratified K-Fold; áp dụng `GridSearchCV` hoặc `RandomizedSearchCV` bài bản.	Tối ưu siêu tham số khoa học; phân tích biểu đồ Validation Curve / Learning Curve; đánh giá khách quan trên Test Set độc lập.

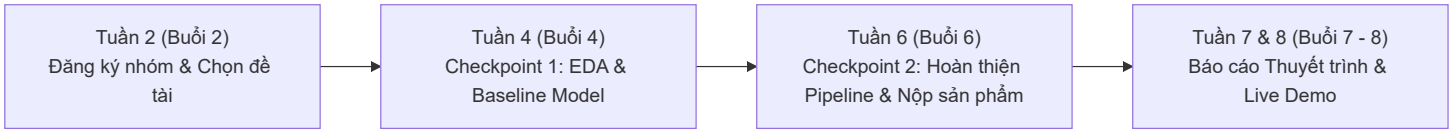
Tiêu chí	Trọng số	Chuẩn đầu ra (CLO)	Mức 1: Kém (0% - 49%)	Mức 2: Đạt (50% - 69%)	Mức 3: Khá - Tốt (70% - 84%)	Mức 4: Xuất sắc (85% - 100%)
			tham số theo cảm tính.	tham số bằng vòng lặp thô sơ.		
4. Chất lượng Báo cáo & Mã nguồn	**15%** (1.5 đ)	**CLO3, CLO4**	Báo cáo cẩu thả, sai định dạng; code không thể chạy lại được, không có chú thích, thiếu file yêu cầu.	Báo cáo đủ cấu trúc cơ bản nhưng phân tích sơ sài; code chạy được nhưng thiếu comment và hướng dẫn.	Báo cáo trình bày đẹp, lập luận logic, bảng biểu rõ ràng; mã nguồn tổ chức khoa học, có `requirements.txt` và `predict.py`.	Báo cáo viết xuất sắc như bài báo khoa học; mã nguồn chuẩn PEP8, có tài liệu hướng dẫn (README) chuyên nghiệp, có file `.joblib`.
5. Thuyết trình, Live Demo & Vấn đáp cá nhân	**20%** (2.0 đ)	**CLO4**	Không chạy được demo; thuyết trình quá giờ; thành viên không trả lời được các câu hỏi cơ bản về code của nhóm.	Thuyết trình còn ấp úng; demo chạy được một phần; trả lời được câu hỏi lý thuyết nhưng lúng túng khi hỏi vào mã nguồn.	Thuyết trình đúng giờ, slide súc tích; Live Demo mượt mà trên dữ liệu mới; các thành viên trả lời tốt câu hỏi vấn đáp.	Thuyết trình cuốn hút, làm chủ thời gian; Demo ấn tượng (có giao diện Webapp như Gradio/Streamlit); trả lời xuất sắc mọi câu hỏi phản biện.

Các Quy định Nghiêm khắc về Điểm số:

1. **Lỗi Rò rỉ Dữ liệu (Data Leakage Penalty):** Nhóm nào thực hiện fit scaler/imputer trên toàn bộ dữ liệu trước khi chia train/test hoặc để lộ thông tin tập test trong cross-validation sẽ bị **trừ trực tiếp từ 1.0 đến 2.0 điểm** vào tổng kết quả.
2. **Gian lận học thuật & Đạo code (Plagiarism):** Nghiêm cấm sao chép nguyên văn đồ án từ khóa trước hoặc tải nguyên project có sẵn trên Kaggle/GitHub mà không hiểu code. Nếu bị phát hiện, toàn bộ nhóm sẽ nhận **điểm 0**.
3. **Phân hóa điểm số cá nhân:** Điểm số cuối cùng của từng sinh viên = $\text{Điểm Nhóm} \times \text{Hệ số Đóng góp cá nhân} \pm \text{Điểm Vấn đáp cá nhân}$. Sinh viên nào không nắm được mã nguồn do nhóm mình nộp sẽ bị hạ điểm độc lập.

IV. LỊCH TRÌNH CÁC MỐC NỘP BÀI (MILESTONES)

Để tránh tình trạng "nước đến chân mới nhảy", quá trình làm Bài tập lớn được chia thành các mốc kiểm tra định kỳ (Checkpoints) trong các buổi thực hành:



Mốc thời gian	Hạn chót	Nội dung bàn giao (Deliverable)	Hình thức kiểm tra
Milestone 0	**Cuối Buổi 2**	• Danh sách thành viên nhóm & Thông tin nhóm trưởng. • Tên đề tài, nguồn dữ liệu và bài toán mục tiêu.	Đăng ký trực tuyến trên biểu mẫu của lớp; GV phê duyệt.
Milestone 1	**Cuối Buổi 4**	• Báo cáo tiến độ 01 (Sơ đồ EDA, chiến lược tiền xử lý). • Mã nguồn Notebook chứa mô hình Baseline đầu tiên.	Giảng viên kiểm tra trực tiếp trên lớp (dành 15 phút cuối buổi).
Milestone 2	**Trước Buổi 7 (24h)**	• Nộp toàn bộ gói sản phẩm (Báo cáo PDF, Slide, Toàn bộ Source code, File `.joblib`).	Đóng hệ thống nộp bài trên LMS.
Milestone 3	**Buổi 7 & Buổi 8**	• Báo cáo thuyết trình trực tiếp tại giảng đường. • Chạy Live Demo và vấn đáp phản biện cá nhân.	Đánh giá trực tiếp tại lớp theo Rubric.

V. DANH SÁCH 15 ĐỀ TÀI GỢI Ý THỰC TẾ

Các đề tài dưới đây được thiết kế đa dạng, kết hợp giữa bài toán kinh tế, tài chính, công nghệ và các bài toán kỹ thuật/công trình xây dựng gắn liền với thế mạnh của Trường ĐH Xây dựng Hà Nội:

Nhóm A: Các bài toán Kỹ thuật & Bất động sản (Thế mạnh HUCE)

1. **Dự báo cường độ chịu nén của Bê tông xi măng (Concrete Compressive Strength Prediction):**
   - *Dữ liệu:* UCI Machine Learning Repository / Kaggle.
   - *Mô tả:* Dự đoán cường độ chịu nén (MPa) dựa trên tỷ lệ thành phần cấp phối (xi măng, xỉ lò cao, tro bay, nước, phụ gia siêu dẻo, cốt liệu thô, cốt liệu mịn, tuổi bê tông).
   - *Dạng bài toán:* Hồi quy (Regression).
2. **Dự đoán Tiêu thụ Năng lượng trong Tòa nhà Thông minh (Building Energy Efficiency):**
   - *Dữ liệu:* UCI Energy Efficiency Dataset.
   - *Mô tả:* Dự đoán tải trọng sưởi ấm (Heating Load) và tải trọng làm mát (Cooling Load) của tòa nhà dựa trên các thông số kiến trúc (diện tích bề mặt, diện tích tường, diện tích mái kính, hướng nhà).

- *Dạng bài toán:* Hồi quy đa mục tiêu / Hồi quy đơn.

3. **Định giá Bất động sản và Biến động Giá nhà Đô thị (Real Estate Valuation):**
   - *Dữ liệu:* California Housing / Ames Housing Dataset.
   - *Mô tả:* Dự báo giá bán nhà ở dựa trên diện tích, vị trí địa lý, số phòng ngủ, chất lượng vật liệu hoàn thiện và niên hạn công trình.
   - *Dạng bài toán:* Hồi quy (Regression).
4. **Dự báo Mức độ Ô nhiễm Không khí Đô thị ($PM_{2.5}$ Air Quality Index):**
   - *Dữ liệu:* OpenAQ / Dữ liệu quan trắc không khí Hà Nội & Bắc Ninh.
   - *Mô tả:* Dự báo nồng độ bụi mịn $PM_{2.5}$ dựa trên các chỉ số khí tượng (nhiệt độ, độ ẩm, áp suất khí quyển, tốc độ gió, lượng mưa).
   - *Dạng bài toán:* Hồi quy (Regression).

Nhóm B: Tài chính, Ngân hàng & Quản trị Rủi ro

5. **Chấm điểm Tín dụng & Dự báo Rủi ro Vỡ nợ Cá nhân (Credit Risk Scoring):**
   - *Dữ liệu:* Home Equity Dataset (HMEQ) / German Credit Dataset.
   - *Mô tả:* Phân loại khách hàng vay vốn có khả năng vỡ nợ (Bad Loan) hay trả nợ đúng hạn dựa trên lịch sử tín dụng, thu nhập, dư nợ và giá trị tài sản thế chấp.
   - *Dạng bài toán:* Phân loại nhị phân (Binary Classification) - Mất cân bằng dữ liệu.
6. **Phát hiện Giao dịch Gian lận Thẻ Tín dụng (Credit Card Fraud Detection):**
   - *Dữ liệu:* Kaggle Credit Card Fraud Detection (284,807 giao dịch).
   - *Mô tả:* Nhận diện các hành vi gian lận tài chính trực tuyến trong bối cảnh dữ liệu cực kỳ mất cân bằng (tỷ lệ gian lận chỉ khoảng 0.17%).
   - *Dạng bài toán:* Phân loại (Imbalanced Classification), tối ưu hóa Recall và PR-AUC.
7. **Dự báo Chi phí Bồi thường Bảo hiểm Y tế Cá nhân (Medical Insurance Cost Prediction):**
   - *Dữ liệu:* US Medical Insurance Cost Dataset.
   - *Mô tả:* Ước tính chi phí viện phí hằng năm của khách hàng dựa trên độ tuổi, chỉ số khối cơ thể (BMI), số con, thói quen hút thuốc và khu vực cư trú.
   - *Dạng bài toán:* Hồi quy (Regression).

Nhóm C: Kinh doanh, Viễn thông & Thương mại Điện tử

8. **Dự đoán Khách hàng Rời bỏ Dịch vụ Viễn thông (Telco Customer Churn Prediction):**
   - *Dữ liệu:* Telco Customer Churn Dataset.
   - *Mô tả:* Nhận diện sớm các khách hàng chuẩn bị hủy hợp đồng sử dụng mạng viễn thông/internet để kịp thời đưa ra chính sách chăm sóc khách hàng.
   - *Dạng bài toán:* Phân loại nhị phân (Binary Classification).
9. **Phân loại Phân khúc Khách hàng & Giá trị Trọn đời (Customer Segmentation & LTV):**
   - *Dữ liệu:* Online Retail II Dataset / Mall Customer Segmentation.
   - *Mô tả:* Kết hợp mô hình Gom cụm không giám sát (K-Means, PCA) với mô hình Phân loại có giám sát để phân nhóm hành vi mua sắm RFM (Recency, Frequency, Monetary).

- *Dạng bài toán:* Học không giám sát kết hợp Phân loại.

10. **Phân tích Cảm xúc Đánh giá Sản phẩm Thương mại Điện tử (Product Review Sentiment Analysis):**
    - *Dữ liệu:* Shopee / Tiki / Amazon Reviews Dataset.
    - *Mô tả:* Trích xuất đặc trưng văn bản bằng TF-IDF kết hợp các thuật toán học máy (Naive Bayes, Logistic Regression, Random Forest) để phân loại bình luận Tích cực / Tiêu cực.
    - *Dạng bài toán:* Phân loại văn bản (Text Classification).

Nhóm D: Y tế, Giao thông & Xã hội

11. **Sàng lọc & Dự báo Nguy cơ Mắc Bệnh Tim Mạch (Cardiovascular Disease Risk Prediction):**
    - *Dữ liệu:* Heart Disease Dataset (Cleveland / Framingham Study).
    - *Mô tả:* Phân loại nguy cơ đột quỵ hoặc suy tim từ các chỉ số sinh hóa lâm sàng (huyết áp, cholesterol, đường huyết lúc đói, điện tâm đồ ECG).
    - *Dạng bài toán:* Phân loại (Classification).
12. **Dự báo Trễ chuyến Bay Hàng không (Flight Delay Prediction):**
    - *Dữ liệu:* US Bureau of Transportation Statistics (BTS).
    - *Mô tả:* Dự đoán chuyến bay có bị hoãn quá 15 phút hay không dựa trên sân bay khởi hành, thời gian cất cánh, hãng hàng không và điều kiện thời tiết.
    - *Dạng bài toán:* Phân loại (Classification).
13. **Cảnh báo Sớm Nguy cơ Sinh viên Thôi học / Cảnh báo Học tập (Student Academic Attrition):**
    - *Dữ liệu:* Higher Education Student Performance Dataset.
    - *Mô tả:* Dự đoán nguy cơ sinh viên bị cảnh báo học tập hoặc bỏ học dựa trên kết quả thi học phần cơ sở, số tín chỉ đăng ký, điểm chuyên cần và tình trạng học phí.
    - *Dạng bài toán:* Phân loại đa lớp (Multi-class Classification).
14. **Phân loại Nấm Độc & Nấm Ăn được trong Tự nhiên (Mushroom Classification):**
    - *Dữ liệu:* UCI Mushroom Dataset.
    - *Mô tả:* Phân loại 100% chính xác nấm độc dựa trên các đặc trưng hình thái (hình dạng mũ nấm, mùi, màu mang nấm, hình dạng cuống).
    - *Dạng bài toán:* Phân loại nhị phân với yêu cầu False Positive = 0 (an toàn tính mạng).
15. **Dự báo Nhu cầu Thuê Xe đạp Công cộng Đô thị (Bike Sharing Demand Forecasting):**
    - *Dữ liệu:* Seoul Bike Sharing Demand / Capital Bikeshare.
    - *Mô tả:* Dự báo số lượng xe đạp được thuê theo từng khung giờ trong ngày dựa trên thời tiết, ngày trong tuần, ngày lễ và nhiệt độ.
    - *Dạng bài toán:* Hồi quy (Regression).