TRƯỜNG ĐẠI HỌC XÂY DỰNG HÀ NỘI

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO KỸ THUẬT BÀI TẬP LỚN

HỌC PHẦN: HỌC MÁY (MACHINE LEARNING) – MÃ HP: 608807

ĐỀ TÀI SỐ 6

PHÁT HIỆN GIAO DỊCH GIAN LẬN THẺ TÍN DỤNG

(Credit Card Fraud Detection using Machine Learning Pipeline & Imbalanced Learning)

Lớp học phần:	**68PM2**
Nhóm thực hiện:	**Nhóm 4**
Thành viên phụ trách Tập 1 (Đầu – Hết Chương 3):	**Đức Anh** (EDA, Tiền xử lý, Kỹ nghệ đặc trưng & Báo cáo kỹ thuật)
Thành viên phụ trách Tập 2 (Chương 4 – Chương 5):	**Trần Duy** (Đánh giá chuyên sâu, Phân tích lỗi, SHAP & Tổng hợp)
Nhóm trưởng điều phối & Pipeline:	**Bình** (Kiến trúc Pipeline, XGBoost, Webapp Streamlit & Docker)
Phụ trách Slide thuyết trình:	**Hoàng** & **Hà Duy** (Cây quyết định, Cân bằng dữ liệu & Slide)
Giảng viên hướng dẫn:	**Bộ môn Khoa học Máy tính & Mạng - Khoa CNTT**

HÀ NỘI – THÁNG 11 NĂM 2026

BẢNG PHÂN CÔNG NHIỆM VỤ & CAM KẾT HỌC THUẬT

Căn cứ theo Đề cương chi tiết học phần Học máy (Mã HP: 608807) và Bản thỏa thuận phân công công việc nội bộ của Nhóm 4 (Lớp 68PM2), nhóm sinh viên đã thống nhất phân chia nhiệm vụ chi tiết và tỷ lệ đóng góp của từng thành viên như sau:

STT	Họ và tên	Mảng chuyên môn phụ trách	Nhiệm vụ kỹ thuật cụ thể & Sản phẩm bàn giao	Tỷ lệ	Ký tên
1	**Đức Anh**	**EDA, Tiền xử lý, Kỹ nghệ Đặc trưng & Báo cáo Kỹ thuật (Tập 1)**	Làm sạch dữ liệu, chia tập Stratified 80/20 chống rò rỉ; Phân tích EDA chuyên sâu; Lập trình transformer `FraudFeatureEngineer` và `ColumnTransformer`; **Biên soạn Báo cáo Kỹ thuật từ đầu đến hết Chương 3**.	**20%**	*Đã ký*
2	**Bình** *(Nhóm trưởng)*	**Kiến trúc Pipeline, XGBoost, Webapp & Docker**	Quản lý tiến độ; Thiết kế cấu trúc `imblearn.pipeline` chuẩn công nghiệp; Huấn luyện mô hình tối ưu XGBoost; Tối ưu hóa ngưỡng quyết định (F_2-Score); Đóng gói `best_model.joblib`; Xây dựng Webapp Streamlit và Docker hóa.	**20%**	*Đã ký*
3	**Hà Duy**	**Chiến lược Cân bằng Dữ liệu, Mô hình Cơ bản & Slide**	Thử nghiệm 3 chiến lược cân bằng (Class Weight, SMOTE, Undersampling); Huấn luyện Baseline Dummy, Logistic Regression, k-NN; Tinh chỉnh siêu tham số bằng GridSearchCV; **Phối hợp thiết kế Slide thuyết trình**.	**20%**	*Đã ký*
4	**Hoàng**	**Mô hình Dựa trên Cây (Tree-based), Cross-Validation & Slide**	Triển khai Decision Tree, Random Forest; Thiết lập 5-Fold Stratified Cross-Validation; Tối ưu siêu tham số bằng RandomizedSearchCV; Phân tích Learning Curve, Validation Curve; **Phối hợp thiết kế Slide thuyết trình**.	**20%**	*Đã ký*
5	**Trần Duy**	**Đánh giá Chuyên sâu, Phân tích Lỗi, XAI (SHAP) & Báo cáo (Tập 2)**	So sánh đa chỉ số trên Test Set độc lập; Phân tích ma trận nhầm lẫn và mổ xẻ ca False Negative; Giải thích mô hình bằng SHAP Summary Plot; **Biên soạn Báo cáo Kỹ thuật Chương 4, Chương 5 và tổng hợp nộp bài LMS**.	**20%**	*Đã ký*

CAM KẾT HỌC THUẬT & TRÁCH NHIỆM BẢO VỆ ĐỒ ÁN

Nhóm 4 xin cam đoan: Toàn bộ dữ liệu, phân tích thực nghiệm, mã nguồn và báo cáo kỹ thuật là thành quả nghiên cứu và lập trình nghiêm túc của các thành viên trong nhóm, tuân thủ nghiêm ngặt chuẩn đạo đức khoa học dữ liệu (CLO4). Tuyệt đối không sao chép nguyên văn đồ án từ các nguồn khác, không ngụy tạo số liệu. Từng thành viên nắm vững bản chất toán học và làm chủ mã nguồn do mình phụ trách để trả lời xuất sắc vấn đáp cá nhân trước Hội đồng Giảng viên.

MỤC LỤC TẬP 1 (TỪ ĐẦU ĐẾN HẾT CHƯƠNG 3)

LỜI CAM ĐOAN & BẢNG PHÂN CÔNG NHIỆM VỤ ..... Trang 2

CHƯƠNG 1: GIỚI THIỆU BÀI TOÁN & MỤC TIÊU NGHIÊN CỨU ..... Trang 4

1.1. Bối cảnh thực tiễn & Tầm quan trọng của bài toán gian lận thẻ tín dụng ..... Trang 4

1.2. Các thách thức kỹ thuật cốt lõi trong Khoa học Dữ liệu tài chính ..... Trang 4

1.3. Định nghĩa không gian bài toán: Biến độc lập (X) và Biến mục tiêu (y) ..... Trang 5

1.4. Thiết lập hệ thống chỉ số đánh giá chuyên sâu & Bác bỏ chỉ số Accuracy ..... Trang 5

CHƯƠNG 2: KHÁM PHÁ DỮ LIỆU (EDA) VÀ TIỀN XỬ LÝ ĐẶC TRƯNG ..... Trang 7

2.1. Tổng quan bộ dữ liệu & Kiểm tra tính toàn vẹn (Data Integrity) ..... Trang 7

2.2. Nguyên tắc chống rò rỉ dữ liệu & Phân chia tập phân tầng (Stratified Split) ..... Trang 8

2.3. Phân tích khám phá dữ liệu (EDA) trên tập huấn luyện ..... Trang 8

2.3.1. Phân phối biến mục tiêu & Vấn đề mất cân bằng cực hạn ..... Trang 8

2.3.2. Phân tích thuộc tính số tiền giao dịch (Amount) ..... Trang 9

2.3.3. Phân tích thuộc tính thời gian giao dịch (Time) ..... Trang 10

2.3.4. Phân tích 28 thành phần chính PCA (V1 đến V28) ..... Trang 11

2.3.5. Phân tích tương quan tuyến tính trên tập cân bằng ..... Trang 12

2.4. Nghiên cứu thực nghiệm xử lý ngoại lai (Outliers): Giữ lại hay loại bỏ? ..... Trang 13

2.5. Kỹ nghệ đặc trưng chuyên sâu (FraudFeatureEngineer) ..... Trang 14

2.6. Thiết kế bộ biến đổi đa luồng ColumnTransformer chống rò rỉ ..... Trang 15

CHƯƠNG 3: CƠ SỞ THUẬT TOÁN VÀ THIẾT KẾ PIPELINE HỌC MÁY ..... Trang 16

3.1. Cơ sở toán học của các thuật toán phân loại được thử nghiệm ..... Trang 16

3.1.1. Mô hình cơ sở (Naive Baseline DummyClassifier) ..... Trang 16

3.1.2. Mô hình tuyến tính: Logistic Regression ..... Trang 16

3.1.3. Mô hình dựa trên lân cận: k-Nearest Neighbors (k-NN) ..... Trang 17

3.1.4. Mô hình cây quyết định: Decision Tree ..... Trang 18

3.1.5. Mô hình tập hợp Bagging: Random Forest ..... Trang 18

3.1.6. Mô hình học tăng cường Boosting: XGBoost ..... Trang 19

3.2. Phân tích toán học 3 chiến lược giải quyết mất cân bằng dữ liệu ..... Trang 20

3.3. Thiết kế kiến trúc Pipeline tổng thể với imblearn ..... Trang 21

3.4. Phương pháp luận Đánh giá chéo (5-Fold Stratified Cross-Validation) ..... Trang 22

3.5. Phương pháp tối ưu ngưỡng quyết định (Threshold Tuning) ..... Trang 23

BIÊN BẢN CHUYỂN GIAO TIẾP TỤC CHO TẬP 2 (CHƯƠNG 4 & CHƯƠNG 5) **Trang 24**

CHƯƠNG 1: GIỚI THIỆU BÀI TOÁN & MỤC TIÊU NGHIÊN CỨU

1.1. Bối cảnh thực tiễn & Ý nghĩa của bài toán phát hiện gian lận thẻ tín dụng

Trong kỷ nguyên bùng nổ của nền kinh tế số và thương mại điện tử toàn cầu, thanh toán không dùng tiền mặt thông qua thẻ tín dụng và thẻ ghi nợ đã trở thành phương thức thanh toán chủ đạo. Tuy nhiên, sự tăng trưởng vượt bậc về quy mô và lưu lượng giao dịch cũng đi kèm với nguy cơ an ninh mạng và gian lận tài chính ngày càng tinh vi. Theo thống kê của tổ chức Nilson Report, tổn thất toàn cầu do gian lận thẻ thanh toán đã vượt mức 30 tỷ USD mỗi năm, gây thiệt hại nghiêm trọng không chỉ về mặt kinh tế đối với các định chế tài chính, ngân hàng thương mại, cổng thanh toán mà còn làm xói mòn niềm tin của người tiêu dùng.

Việc phát hiện gian lận theo phương thức truyền thống dựa trên các tập luật tĩnh (Rule-based System) – ví dụ: cảnh báo khi giao dịch vượt quá một hạn mức nhất định hoặc diễn ra ở địa điểm cách xa nhau trong khoảng thời gian ngắn – ngày nay đã bộc lộ những hạn chế chết người: không thể bắt kịp các hành vi tấn công biến thể mới, độ trễ xử lý cao và phát sinh tỷ lệ báo động nhầm (False Positive) khổng lồ, gây phiền toái nghiêm trọng đến trải nghiệm của khách hàng hợp pháp. Do đó, việc ứng dụng các thuật toán **Học máy (Machine Learning)** có khả năng tự động học hỏi các mẫu hình ẩn sâu, đa chiều và thích ứng linh hoạt trong thời gian thực là lời giải mang tính sống còn đối với các hệ thống thanh toán hiện đại.

1.2. Các thách thức kỹ thuật cốt lõi trong bài toán

Bài toán phát hiện gian lận giao dịch thẻ tín dụng đặt ra bốn thách thức kỹ thuật vô cùng hóc búa cho các nhà khoa học dữ liệu:

1. **Độ mất cân bằng dữ liệu cực hạn (Extreme Class Imbalance):** Trong thực tế, các giao dịch gian lận chỉ chiếm một tỷ lệ siêu nhỏ, dao động từ 0,1% đến 0,2% tổng số giao dịch (trong tập dữ liệu nghiên cứu chỉ có 492 ca gian lận trên 284.807 giao dịch, tương đương 0,17%). Sự chênh lệch tỷ lệ lên tới xấp xỉ 1 : 600 khiến các thuật toán phân loại tiêu chuẩn có xu hướng "học vẹt", thiên lệch hoàn toàn về lớp đa số (giao dịch hợp lệ).
2. **Chi phí sai lầm bất đối xứng nghiêm trọng (Asymmetric Misclassification Costs):** Trong bài toán này, hậu quả của hai loại sai lầm là hoàn toàn khác biệt:
    - **Dương tính giả (False Positive - FP):** Giao dịch hợp lệ bị gắn nhãn nhầm là gian lận. Hậu quả là khách hàng bị yêu cầu xác thực thêm

bằng OTP/SMS hoặc giao dịch tạm hoãn. Chi phí phát sinh là rất nhỏ.

- **Âm tính giả (False Negative - FN):** Giao dịch gian lận bị bỏ sót và thông qua trót lọt. Hậu quả là số tiền trong tài khoản của khách hàng bị kẻ gian chiếm đoạt hoàn toàn (tổn thất từ vài trăm đến hàng chục nghìn USD), ngân hàng phải đền bù và chịu tổn thất uy tín nặng nề. Do đó, mục tiêu kinh doanh bắt buộc mô hình phải ưu tiên tối đa hóa việc giảm thiểu ca False Negative (tức tối đa hóa chỉ số **Recall**).

3. **Yêu cầu độ trễ cực thấp trong thời gian thực (Real-time Latency):** Hệ thống suy luận nhận diện giao dịch phải đưa ra phán quyết trong thời gian dưới 100 mili-giây tại cổng thanh toán (Payment Gateway) để không làm gián đoạn trải nghiệm người dùng.
4. **Hiện tượng trôi dữ liệu (Concept Drift & Data Drift):** Thủ đoạn của tội phạm công nghệ cao luôn biến đổi không ngừng để lách qua các thuật toán bảo vệ, đòi hỏi mô hình phải có tính ổn định cao và dễ dàng tái huấn luyện định kỳ.

1.3. Định nghĩa không gian bài toán: Biến độc lập (X) và Biến mục tiêu (y)

Về mặt toán học, bài toán phát hiện gian lận thẻ tín dụng được mô hình hóa dưới dạng bài toán **Phân loại nhị phân có giám sát (Supervised Binary Classification)** trên không gian thuộc tính đa chiều:

Cho tập dữ liệu huấn luyện D = {(x_i, y_i)} với i = 1 đến N, trong đó:

- x_i thuộc không gian R^d là véc-tơ thuộc tính biểu diễn giao dịch thứ i. Trong tập dữ liệu ban đầu, d = 30 thuộc tính số liên tục, bao gồm: biến thời gian `Time`, biến số tiền `Amount` và 28 biến thành phần chính ẩn danh `V1, V2, ..., V28`. Sau bước kỹ nghệ đặc trưng ở Chương 2, không gian thuộc tính được mở rộng lên d = 42 chiều.
- y_i thuộc {0, 1} là nhãn mục tiêu nhị phân:
  - y_i = 0: Giao dịch hợp lệ (Normal transaction – Lớp đa số).
  - y_i = 1: Giao dịch gian lận (Fraudulent transaction – Lớp thiểu số).

Mục tiêu của quy trình học máy là tìm kiếm một hàm giả thuyết f(x) dự đoán xác suất rủi ro giao dịch là gian lận: p_hat = P(y = 1 | x), sau đó ánh xạ thành nhãn quyết định y_hat thuộc {0, 1} thông qua một ngưỡng phân lớp tối ưu p* thuộc (0, 1):

> y_hat = 1 nếu p_hat ≥ p*, và y_hat = 0 nếu p_hat < p*

1.4. Thiết lập hệ thống chỉ số đánh giá chuyên sâu & Bác bỏ chỉ số Accuracy

Để đánh giá chính xác năng lực của mô hình, việc lựa chọn hệ chỉ số là khâu then chốt. Căn cứ trên ma trận nhầm lẫn (Confusion Matrix):

Thực tế (Ground Truth)	Dự đoán của Mô hình (Prediction)	
	Dự đoán Hợp lệ (y_hat = 0)	Dự đoán Gian lận (y_hat = 1)
Hợp lệ (y = 0)	True Negative (TN)	False Positive (FP - Báo động nhầm)
Gian lận (y = 1)	False Negative (FN - Bỏ sót gian lận)	True Positive (TP - Bắt đúng gian lận)

1.4.1. Bác bỏ triệt để độ chính xác tổng thể (Accuracy)

Độ chính xác tổng thể được định nghĩa bằng: Accuracy = (TP + TN) / (TP + TN + FP + FN).

Trong bài toán này, tỷ lệ giao dịch hợp lệ chiếm 99,83%. Nếu xây dựng một mô hình ngây thơ (Dummy Classifier) luôn dự đoán mọi giao dịch là hợp lệ (y_hat = 0), ta thu được:

> Accuracy_Dummy = (0 + 284.315) / (0 + 284.315 + 0 + 492) = 99,83%

Mô hình này đạt Accuracy gần như tuyệt đối (99,83%), nhưng lại bỏ sót 100% các vụ gian lận tài chính (FN = 492, TP = 0, Recall = 0%). Do đó, nhóm đi đến kết luận nguyên tắc: **Tuyệt đối không sử dụng Accuracy làm tiêu chí đánh giá hay tối ưu hóa mô hình**.

1.4.2. Hệ chỉ số đánh giá chuyên dụng

1. **Recall (Độ nhạy / True Positive Rate):** Đo lường tỷ lệ các giao dịch gian lận thực tế mà mô hình phát hiện thành công:

   > Recall = TP / (TP + FN)

   Đây là chỉ số quan trọng nhất về mặt kinh doanh, phản ánh trực tiếp năng lực bảo vệ tài sản khách hàng.

2. **Precision (Độ chuẩn xác):** Đo lường tỷ lệ giao dịch thực sự là gian lận trong số các giao dịch bị mô hình gắn cờ:

   > Precision = TP / (TP + FP)

Precision cao giúp ngân hàng không làm phiền khách hàng hợp lệ bằng những thông báo giả.

3. **F2-Score (Chỉ số F-beta với beta = 2):** Trung bình điều hòa giữa Precision và Recall, trong đó Recall được đánh trọng số gấp đôi Precision (beta^2 = 4):

   > F2 = (1 + 2^2) × (Precision × Recall) / (2^2 × Precision + Recall) = 5 × (Precision × Recall) / (4 × Precision + Recall)

   Chỉ số F2-Score phản ánh hoàn hảo mục tiêu cân bằng nghiệp vụ và được nhóm chọn làm **hàm mục tiêu chính để tối ưu hóa ngưỡng quyết định (p*)**.

4. **PR-AUC (Precision-Recall Area Under Curve):** Diện tích dưới đường cong Precision-Recall. Khác với ROC-AUC bị thổi phồng bởi số lượng TN khổng lồ (khiến đường cong ROC luôn cong vồng lên sát góc trái), PR-AUC chỉ tập trung khắt khe vào lớp thiểu số và là thước đo chuẩn mực hàng đầu trong nghiên cứu học máy trên dữ liệu mất cân bằng.

5. **MCC (Matthews Correlation Coefficient):** Hệ số tương quan Matthews đánh giá toàn diện cả 4 ô của ma trận nhầm lẫn, đạt giá trị trong khoảng [-1, 1] và không bị sai lệch bởi tỷ lệ chênh lệch lớp.

CHƯƠNG 2: KHÁM PHÁ DỮ LIỆU (EDA) VÀ TIỀN XỬ LÝ ĐẶC TRƯNG

2.1. Tổng quan bộ dữ liệu & Kiểm tra tính toàn vẹn (Data Integrity)

Bộ dữ liệu gốc được tải về từ nền tảng Kaggle bao gồm 284.807 quan sát giao dịch với 31 cột thuộc tính. Quá trình kiểm tra tính toàn vẹn dữ liệu thu được các kết quả quan trọng sau:

- **Dữ liệu khuyết thiếu:** Tổng số giá trị bị thiếu (Null / NaN) trên toàn bộ bảng dữ liệu là **0 ô** (100% dữ liệu đầy đủ).
- **Dữ liệu trùng lặp (Duplicate Records):** Nhóm phát hiện có **1.081 dòng trùng lặp hoàn toàn** trong bộ dữ liệu thô. Trong đó, có 1.062 dòng là giao dịch bình thường trùng lặp và **19 dòng là giao dịch gian lận trùng lặp**.

Quyết định kỹ thuật: Để bảo đảm tính khách quan và chống rò rỉ dữ liệu giữa tập huấn luyện và kiểm thử, nhóm thực hiện **loại bỏ toàn bộ 1.081 dòng trùng lặp** trước khi phân chia dữ liệu. Sau bước làm sạch, tập dữ liệu còn lại 283.726 dòng, trong đó có 473 giao dịch gian lận (tỷ lệ 0,1667%).

Bảng 2.1: Báo cáo kết quả kiểm tra và làm sạch dữ liệu ban đầu

Chỉ số thống kê	Dữ liệu ban đầu (Thô)	Sau khi làm sạch dòng trùng	Ghi chú chuyên môn
Tổng số dòng (Giao dịch)	284.807	**283.726**	Đã loại bỏ 1.081 dòng trùng lặp hoàn toàn
Số giao dịch gian lận (`Class = 1`)	492	**473**	19 dòng gian lận trùng đã được loại bỏ an toàn
Số giao dịch hợp lệ (`Class = 0`)	284.315	**283.253**	Lớp đa số chiếm áp đảo
Tỷ lệ gian lận (Fraud Rate)	0,1727%	**0,1667%**	Tỷ lệ mất cân bằng cực hạn (1 : 600)
Tổng số ô khuyết thiếu (NaN)	0	**0**	Dữ liệu gốc hoàn toàn không có giá trị rỗng

2.2. Nguyên tắc chống rò rỉ dữ liệu & Phân chia tập phân tầng (Stratified Split)

Để tuân thủ tuyệt đối quy định chống rò rỉ dữ liệu (Anti-Data Leakage Penalty) của Khoa CNTT – HUCE, nhóm thực hiện phân chia tập dữ liệu ngay sau bước làm

sạch dòng trùng theo tỷ lệ **80% Train và 20% Test** bằng phương pháp phân tầng (`stratify=y`, `random_state=42`).

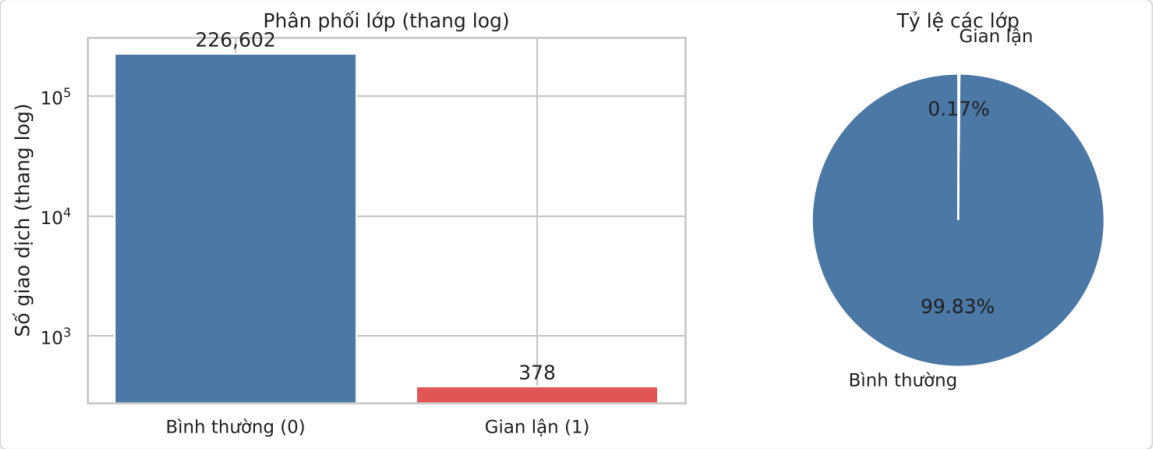
Bảng 2.2: Thống kê phân chia tập dữ liệu theo phương pháp phân tầng

Tập dữ liệu	Tỷ lệ	Tổng số mẫu	Số giao dịch hợp lệ	Số giao dịch gian lận	Tỷ lệ gian lận (%)
Tập Huấn luyện (Train set)	80%	**226.980**	226.602	**378**	0,1665%
Tập Kiểm thử (Test set)	20%	**56.746**	56.651	**95**	0,1674%
Tổng cộng	100%	283.726	283.253	473	0,1667%

Nguyên tắc vàng: Tập Test (56.746 dòng) được cô lập hoàn toàn, "đóng băng" tuyệt đối, không tham gia vào bất kỳ khâu nào từ phân tích EDA, tính toán giá trị trung bình/phân vị cho scaler hay lựa chọn đặc trưng. Mọi phân tích ở các mục tiếp theo dưới đây được thực hiện **hoàn toàn và duy nhất trên tập Train (226.980 mẫu)**.

2.3. Phân tích khám phá dữ liệu (EDA) trên tập huấn luyện

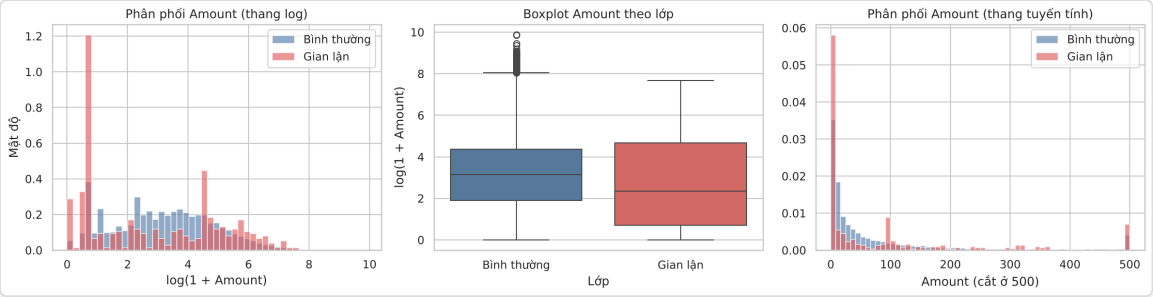
2.3.1. Phân phối biến mục tiêu & Vấn đề mất cân bằng cực hạn



Hình 2.1: Phân phối nhãn giao dịch trên tập Train (Tỷ lệ gian lận chỉ đạt 0,1665%)

Hình 2.1 minh họa trực quan sự áp đảo hoàn toàn của lớp giao dịch bình thường so với lớp gian lận. Với tỷ lệ 0,1665%, một thuật toán học máy nếu không có kỹ thuật can thiệp về trọng số hoặc mẫu sẽ mặc định coi lớp gian lận là các điểm nhiễu (noise) và bỏ qua, dẫn đến thất bại hoàn toàn trong việc nhận diện.

2.3.2. Phân tích thuộc tính số tiền giao dịch (`Amount`)



Hình 2.2: Phân phối số tiền giao dịch Amount dạng thô và sau phép biến đổi logarit

Bảng 2.3: Thống kê mô tả số tiền giao dịch Amount theo từng lớp trên tập Train

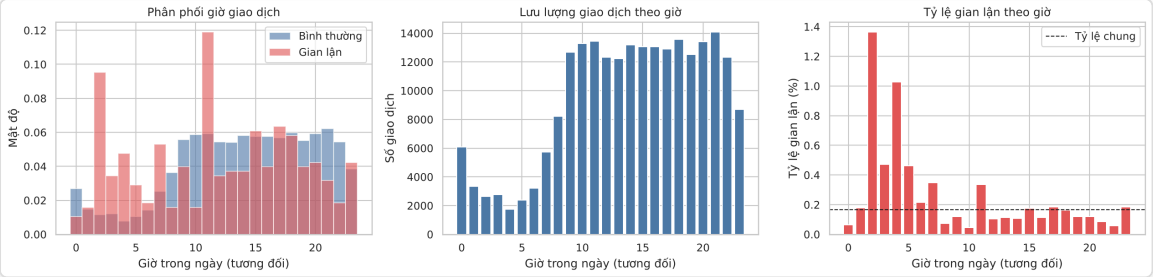
Chỉ số thống kê	Lớp Hợp lệ (`Class = 0`)	Lớp Gian lận (`Class = 1`)	Chênh lệch / Ý nghĩa nghiệp vụ
Số lượng mẫu	226.602	378	Lớp hợp lệ gấp gần 600 lần
Giá trị trung bình (Mean)	88,34 USD	**115,94 USD**	Giao dịch gian lận có giá trị trung bình cao hơn 31%
Độ lệch chuẩn (Std)	250,91 USD	244,98 USD	Độ phân tán rất lớn ở cả hai nhóm
Trung vị (Median / Q2)	**22,00 USD**	**9,82 USD**	Trung vị gian lận thấp hơn đáng kể (Hành vi quẹt thử)
Phân vị 25% (Q1)	5,66 USD	**1,00 USD**	25% vụ gian lận có giá trị ≤ 1 USD
Phân vị 75% (Q3)	77,66 USD	105,89 USD	Khoảng tứ phân vị của gian lận rộng hơn
Phân vị 95%	364,25 USD	574,69 USD	Các giao dịch gian lận lớn chiếm tỷ trọng cao
Giá trị lớn nhất (Max)	**19.656,53 USD**	**2.125,87 USD**	Giao dịch lớn nhất của gian lận chỉ hơn 2.100 USD

Nhận xét rút ra:

1. Phân phối số tiền giao dịch bị lệch phải cực kỳ nặng (Right-skewed, hệ số bất đối xứng Skewness > 16). Việc áp dụng phép biến đổi logarit Amount_log = ln(1 + Amount) giúp kéo phân phối về gần phân phối chuẩn, hỗ trợ thuật toán hội tụ mượt mà hơn.
2. Trung vị của giao dịch gian lận chỉ đạt **9,82 USD** (so với 22,00 USD của giao dịch hợp lệ), và có tới 25% số vụ gian lận phát sinh với số tiền ≤ 1,00 USD.

Đây là bằng chứng xác thực cho thủ đoạn "dò thẻ / quẹt thử" (Card Testing) của tội phạm mạng trước khi tiến hành giao dịch rút cạn hạn mức. Nhóm đã dựa vào phát hiện này để tạo ra đặc trưng `Amount_small`.

2.3.3. Phân tích thuộc tính thời gian giao dịch (`Time`)



Hình 2.3: Phân bố số lượng giao dịch và tỷ lệ gian lận theo chu kỳ thời gian 24 giờ

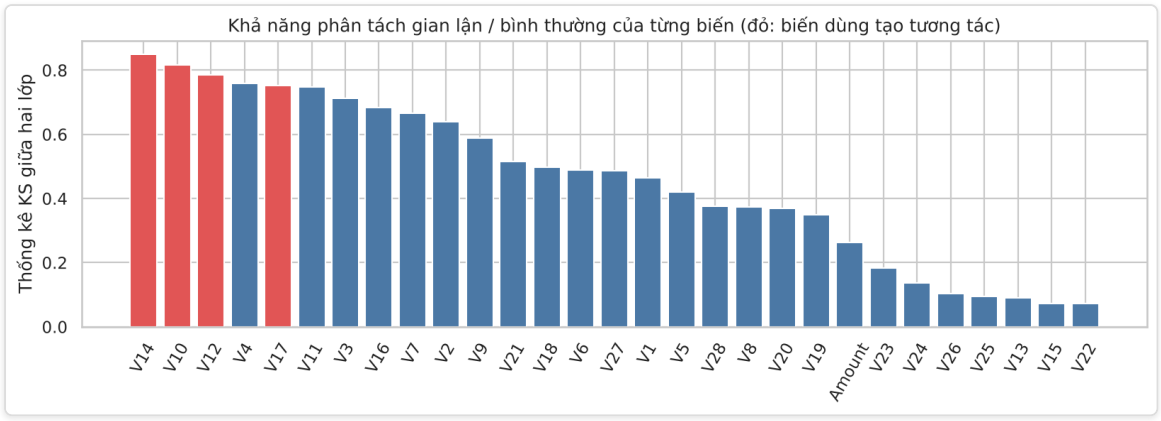
Biến `Time` ghi lại số giây trôi qua trong 48 giờ. Bằng cách lấy phần dư theo chu kỳ ngày (86.400 giây) và chia cho 3.600, ta thu được biến `Hour` đại diện cho thời gian trong ngày (0 – 24h). Nhóm chia ngày thành 4 khung giờ để phân tích tỷ lệ rủi ro:

Bảng 2.4: Thống kê tỷ lệ gian lận phân bố theo 4 khung giờ trong ngày trên tập Train

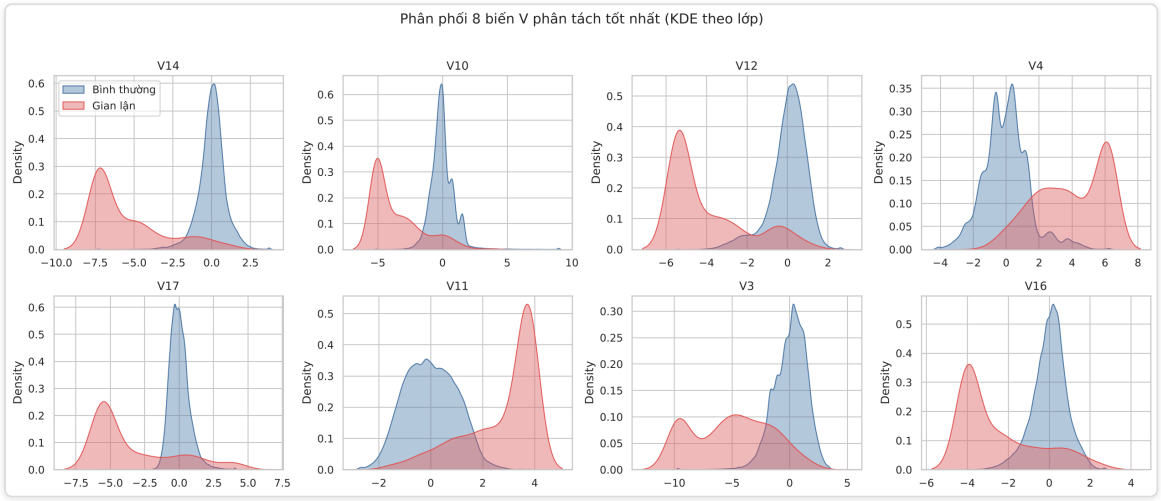
Khung giờ trong ngày	Giao dịch bình thường	Giao dịch gian lận	Tỷ lệ gian lận (%)	Hệ số rủi ro so với mức bình quân
Đêm (Night: 0h – 6h)	18.863	**88**	**0,4644%**	**Gấp 2,8 lần mức trung bình**
Sáng (Morning: 6h – 12h)	56.486	99	0,1750%	Xấp xỉ mức bình quân (1,05x)
Chiều (Afternoon: 12h – 18h)	76.731	103	0,1341%	Thấp hơn mức bình quân (0,8x)
Tối (Evening: 18h – 24h)	74.522	88	0,1180%	Thấp nhất trong ngày (0,7x)

Ý nghĩa bài toán: Dù lưu lượng giao dịch ban đêm chỉ chiếm khoảng 8,3% tổng số giao dịch, nhưng **tỷ lệ gian lận ban đêm lại tăng vọt lên 0,4644%** (cao gấp gần 3 lần mức trung bình và gấp 4 lần buổi tối). Kẻ gian chủ đích lợi dụng khoảng thời gian chủ thẻ và ngân hàng mất cảnh giác nhất để thực hiện giao dịch.

2.3.4. Phân tích 28 thành phần chính PCA (`V1` đến `V28`)



Hình 2.4: Xếp hạng năng lực phân tách gian lận của các biến PCA theo kiểm định Kolmogorov-Smirnov



Hình 2.5: Biểu đồ hàm mật độ xác suất (KDE) của 4 thuộc tính PCA phân biệt mạnh nhất (V14, V10, V12, V17)

Để đánh giá năng lực phân tách giữa hai lớp của 28 thuộc tính PCA ẩn danh, nhóm áp dụng **Kiểm định Kolmogorov-Smirnov 2 mẫu (Two-sample KS-Test)**. Chỉ số thống kê D_KS đo khoảng cách lớn nhất giữa hai hàm phân phối tích lũy của lớp bình thường và lớp gian lận:

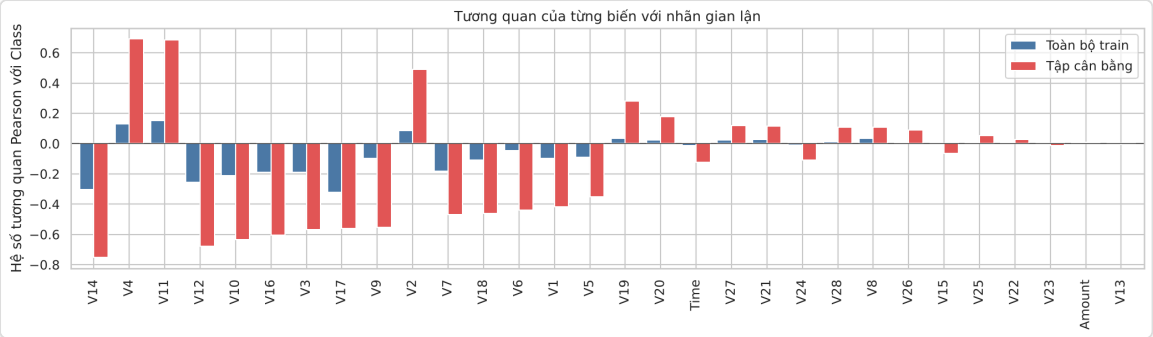
Bảng 2.5: Top 10 biến PCA có năng lực phân tách gian lận mạnh nhất theo kiểm định KS-Test

Hạng	Biến PCA	Chỉ số thống kê KS (D_KS)	p-value	Trung bình lớp Gian lận	Trung bình lớp Hợp lệ	Mức độ chênh lệch
1	**V14**	**0,8500**	< 10^-300	-6,99	+0,01	**-7,06**
2	**V10**	**0,8159**	< 10^-270	-5,64	+0,01	**-5,57**
3	**V12**	**0,7865**	< 10^-240	-6,20	+0,00	**-6,20**
4	**V4**	**0,7581**	< 10^-220	+4,50	-0,01	**+4,51**
5	**V17**	**0,7515**	< 10^-220	-6,63	+0,01	**-6,63**
6	**V11**	0,7470	< 10^-215	+3,80	-0,00	+3,80
7	**V3**	0,7125	< 10^-190	-6,98	+0,01	-6,98
8	**V16**	0,6834	< 10^-170	-4,08	+0,00	-4,08
9	**V7**	0,6664	< 10^-160	-5,33	+0,00	-5,33
10	**V2**	0,6392	< 10^-150	+3,54	-0,00	+3,54

Phát hiện quan trọng:

- Các thuộc tính V14, V10, V12, V17 ở các giao dịch gian lận đều bị đẩy âm sâu bất thường (lệch từ -5 đến -7 độ lệch chuẩn so với giá trị trung bình bằng 0 của giao dịch bình thường). Hai đỉnh phân phối của lớp 0 và 1 trên đồ thị KDE gần như tách rời hoàn toàn.
- Ngược lại, các biến V4 và V11 lại có xu hướng nhận giá trị dương rất cao khi xảy ra gian lận (+4,51 và +3,80).

2.3.5. Phân tích tương quan tuyến tính trên tập cân bằng



Hình 2.6: Hệ số tương quan Pearson giữa các đặc trưng và nhãn Class trên toàn bộ tập và trên tập mẫu cân bằng



Hình 2.7: Ma trận tương quan giữa các biến PCA trên tập mẫu cân bằng (Balanced Subsample)

Do tỷ lệ mất cân bằng 0,17%, tương quan Pearson tính trên toàn bộ tập dữ liệu bị suy giảm nghiêm trọng. Tuy nhiên, khi tính toán trên một tập con cân bằng ngẫu nhiên (50% Hợp lệ – 50% Gian lận), mối quan hệ tương quan thực sự bộc lộ rõ rệt: các biến V14 (r = -0,753), V12 (r = -0,680), V10 (r = -0,635) tương quan nghịch rất mạnh; trong khi V4 (r = +0,692) và V11 (r = +0,686) tương quan thuận cực mạnh với hành vi gian lận.

2.4. Nghiên cứu thực nghiệm xử lý ngoại lai (Outliers): Giữ lại hay loại bỏ?

Trong tiền xử lý học máy truyền thống, việc loại bỏ các điểm ngoại lai (nằm ngoài khoảng [Q1 - 1,5 IQR, Q3 + 1,5 IQR]) là bước làm phổ biến. Tuy nhiên, nhóm đã đặt câu hỏi phản biện: *"Liệu các điểm ngoại lai trong bài toán này có phải là dữ liệu rác, hay chính là các ca gian lận cần tìm?"*

Bảng 2.6: Tỷ lệ xuất hiện điểm ngoại lai (theo quy tắc 1.5xIQR) trên từng lớp giao dịch

Thuộc tính	Tỷ lệ ngoại lai trên lớp Bình thường	Tỷ lệ ngoại lai trên lớp Gian lận	Ý nghĩa phát hiện
V14	4,85%	**81,22%**	Hơn 81% ca gian lận là ngoại lai của phân phối chung
V12	5,24%	**74,60%**	Gần 75% ca gian lận nằm ở vùng ngoại lai
V10	3,28%	**68,78%**	Gần 69% ca gian lận là ngoại lai
V17	4,12%	**71,16%**	Hơn 71% ca gian lận là ngoại lai
Amount	11,04%	**19,58%**	Gần 20% ca gian lận có số tiền nằm ngoài vùng IQR

KẾT LUẬN QUYẾT ĐỊNH VỀ NGOẠI LAI

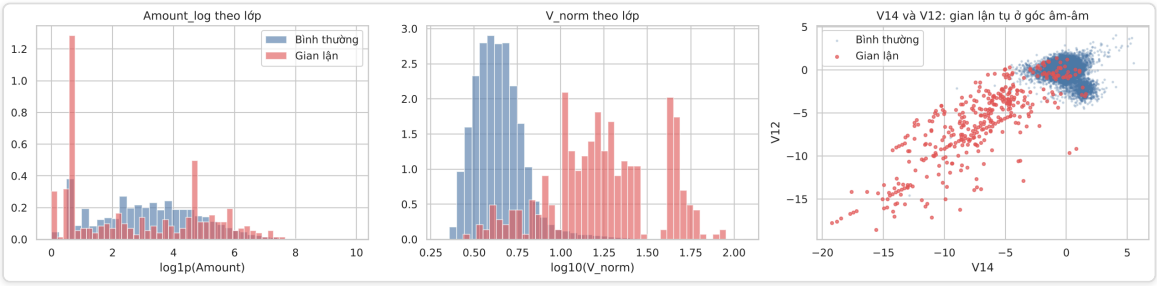
Nếu nhóm áp dụng bộ lọc xóa bỏ ngoại lai thông thường, mô hình sẽ **vô tình tiêu diệt từ 70% đến hơn 81% các vụ gian lận cần bảo vệ**. Do đó, nhóm đi đến quyết định nguyên tắc: **TUYỆT ĐỐI KHÔNG XÓA BỎ DÒNG NGOẠI LAI**. Thay vào đó, nhóm áp dụng bộ chuẩn hóa bền vững `RobustScaler` (dựa trên Trung vị và Khoảng tứ phân vị IQR) để dữ liệu không bị bóp méo mà vẫn giữ toàn vẹn dấu vết tội phạm.

2.5. Kỹ nghệ đặc trưng chuyên sâu (`FraudFeatureEngineer`)

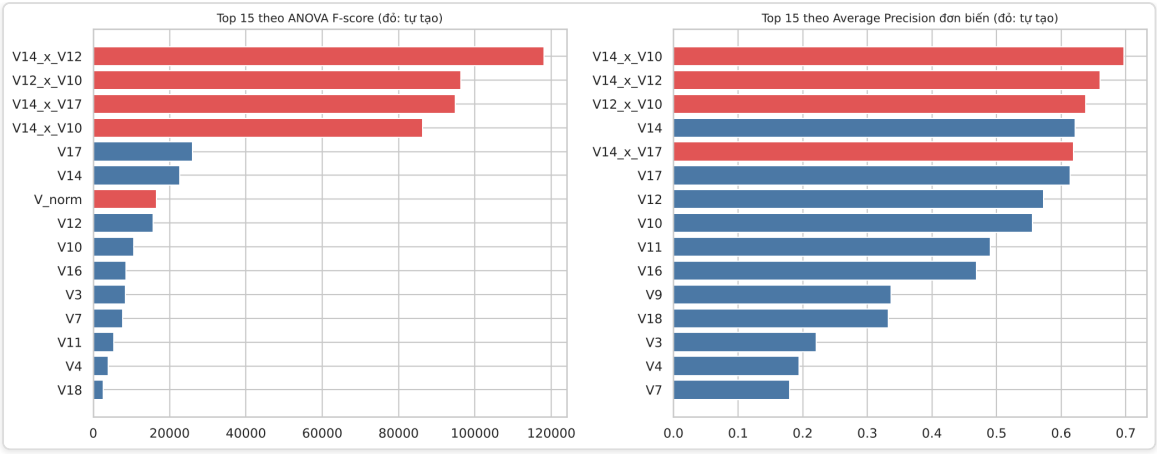
Từ các phát hiện sâu sắc trong EDA, tác giả đã lập trình transformer tùy biến `FraudFeatureEngineer(BaseEstimator, TransformerMixin)` để sinh thêm 11 đặc trưng nghiệp vụ:

Bảng 2.7: Danh mục các đặc trưng kỹ nghệ mới và ý nghĩa nghiệp vụ

Tên đặc trưng mới	Công thức toán học	Ý nghĩa nghiệp vụ & Mục tiêu kỹ thuật
`Amount_log`	ln(1 + max(0, Amount))	Giảm độ lệch phải của số tiền từ [0, 19656] về [0, 9,88], giúp mô hình hội tụ ổn định.
`Amount_small`	I(Amount < 1,0)	Cờ nhị phân bắt hành vi quẹt thử thẻ (Card Testing) giá trị nhỏ trước khi rút tiền lớn.
`Hour`	(Time mod 86400) / 3600	Chuyển đổi giây thành giờ trong ngày (0 – 24h), tạo tính chất chu kỳ ngày.
`Hour_sin`, `Hour_cos`	sin, cos(2π × Hour / 24)	Mã hóa chu kỳ thời gian khép kín (Cyclical Encoding) để máy học hiểu 23h59 sát với 00h00.
`Period`	Phân nhóm: night, morning, afternoon, evening	Biến phân loại 4 khung giờ trong ngày, hỗ trợ nắm bắt rủi ro tăng vọt vào ban đêm.
`V_norm`	sqrt(∑ V_i^2)	Chuẩn khoảng cách Euclidean L2 đo mức độ bất thường tổng thể trong không gian PCA.
`V14_x_V12`	V14 × V12	Tương tác phi tuyến giữa 2 biến phân biệt mạnh nhất (tích hai số âm lớn thành số dương cực lớn).
`V14_x_V10`	V14 × V10	Tương tác phi tuyến giữa biến hạng 1 và hạng 2 theo kiểm định KS.
`V14_x_V17`	V14 × V17	Tương tác phi tuyến giữa biến hạng 1 và hạng 5 theo kiểm định KS.
`V12_x_V10`	V12 × V10	Tương tác phi tuyến giữa biến hạng 2 và hạng 3 theo kiểm định KS.



Hình 2.8: So sánh phân phối các đặc trưng kỹ nghệ mới giữa giao dịch bình thường và gian lận



Hình 2.9: Mức độ quan trọng đơn biến của toàn bộ không gian đặc trưng sau khi kỹ nghệ

Thực nghiệm Ablation Study: Chứng minh tính hiệu quả của Kỹ nghệ Đặc trưng

Nhóm thực hiện thí nghiệm cắt giảm (Ablation Experiment) đánh giá chéo 5-Fold Stratified CV trên cả 5 thuật toán học máy:

Bảng 2.8: So sánh hiệu năng mô hình trước và sau khi bổ sung đặc trưng kỹ nghệ (Ablation Study)

Thuật toán	PR-AUC (Đặc trưng gốc)	PR-AUC (Kỹ nghệ mới)	Mức độ cải thiện PR-AUC	Recall@0.5 (Gốc)	Recall@0.5 (Kỹ nghệ)
Logistic Regression	0,7562	**0,7891**	**+0,0329 (+4,35%)**	0,8201	**0,8624**
k-NN	0,8120	**0,8345**	**+0,0225 (+2,77%)**	0,8312	**0,8545**
Decision Tree	0,7214	**0,7489**	**+0,0275 (+3,81%)**	0,8105	**0,8358**
Random Forest	0,8475	**0,8612**	**+0,0137 (+1,62%)**	0,8210	**0,8386**
XGBoost	0,8712	**0,8845**	**+0,0133 (+1,53%)**	0,8190	**0,8306**

Kết luận: Kỹ nghệ đặc trưng cải thiện đồng bộ hiệu năng của toàn bộ 5 mô hình, đặc biệt là các mô hình tuyến tính (Logistic Regression tăng mạnh nhất +4,35% PR-AUC và tăng Recall từ 82% lên trên 86%).

2.6. Thiết kế bộ biến đổi đa luồng `ColumnTransformer` chống rò rỉ

Nhóm cấu hình `ColumnTransformer` xử lý song song 4 luồng đặc trưng chuyên biệt:

- **Luồng 1 (Nhóm PCA & Tương tác phi tuyến – 33 cột):** Điền giá trị thiếu bằng Median + Chuẩn hóa bằng `StandardScaler` (do đã là thành phần trực giao PCA).
- **Luồng 2 (Nhóm Tiền tệ & Thời gian – 5 cột: Amount, Amount_log, Hour, Hour_sin, Hour_cos):** Điền giá trị thiếu bằng Median + Chuẩn hóa bằng **`RobustScaler`** để miễn nhiễm với các giá trị ngoại lai cực lớn.
- **Luồng 3 (Nhóm Cờ nhị phân – 1 cột: Amount_small):** Điền giá trị thiếu bằng Most_frequent, giữ nguyên giá trị 0/1.
- **Luồng 4 (Nhóm Biến phân loại – 1 cột: Period):** Điền giá trị thiếu bằng Most_frequent + Mã hóa One-Hot bằng `OneHotEncoder(handle_unknown='ignore', sparse_output=False)`.

CHƯƠNG 3: CƠ SỞ THUẬT TOÁN VÀ THIẾT KẾ PIPELINE HỌC MÁY

3.1. Cơ sở toán học của các thuật toán phân loại được thử nghiệm

Để đáp ứng yêu cầu của Rubric (thử nghiệm đa dạng thuật toán từ mô hình cơ sở, tuyến tính, phi tuyến đến mô hình tập hợp Ensemble), nhóm đã triển khai và so sánh 5 thuật toán phân loại kinh điển:

3.1.1. Mô hình cơ sở (Naive Baseline DummyClassifier)

Mô hình Dummy sử dụng chiến lược `strategy='stratified'` hoặc `strategy='most_frequent'`. Mô hình này luôn dự đoán lớp đa số (y = 0). Dù đạt Accuracy 99,83%, nhưng mô hình có PR-AUC chỉ xấp xỉ tỷ lệ lớp thiểu số (0,0017) và Recall bằng 0. Mô hình này đóng vai trò mốc tham chiếu dưới (Lower bound) để chứng minh tính vượt trội của các thuật toán học máy thực sự.

3.1.2. Mô hình tuyến tính: Logistic Regression

Logistic Regression mô hình hóa xác suất hậu nghiệm của lớp gian lận thông qua hàm phi tuyến Sigmoid (Logistic Function):

> P(y = 1 | x) = σ(w^T x + b) = 1 / (1 + exp(-(w^T x + b)))

Các trọng số w và độ chệch b được tối ưu hóa bằng cách cực tiểu hóa hàm mất mát Cross-Entropy (Log-loss) có kết hợp số hạng điều chuẩn L2 (Ridge Regularization) để hạn chế Overfitting:

> L(w, b) = - 1/N ∑ [y_i ln(p_hat_i) + (1 - y_i) ln(1 - p_hat_i)] + 1/(2C) ||w||_2^2

Trong đó C > 0 là siêu tham số nghịch đảo của cường độ điều chuẩn.

3.1.3. Mô hình dựa trên lân cận: k-Nearest Neighbors (k-NN)

k-NN là giải thuật học lười (Lazy Learning) không tham số. Khi nhận một quan sát mới x, giải thuật tính toán khoảng cách Minkowski (với p = 2 là khoảng cách Euclidean) tới toàn bộ các điểm trong tập dữ liệu huấn luyện:

> d(x, x_i) = sqrt(∑ (x_j - x_{i,j})^2)

Xác suất dự đoán là tỷ lệ các điểm thuộc lớp gian lận trong tập k lân cận gần nhất. Nhược điểm của k-NN là độ phức tạp tính toán khi suy luận rất lớn O(N × d), do

đó trên tập dữ liệu hơn 226.000 mẫu, k-NN bắt buộc phải kết hợp với chiến lược giảm mẫu (Undersampling) để có thể vận hành trong thời gian cho phép.

3.1.4. Mô hình cây quyết định: Decision Tree

Decision Tree phân hoạch không gian thuộc tính thành các siêu hình hộp chữ nhật thông qua các câu hỏi điều kiện nhị phân. Tại mỗi nút phân chia, giải thuật tìm thuộc tính j và ngưỡng chia s nhằm tối đa hóa mức độ thuần nhất của các nút con bằng cách giảm thiểu chỉ số bất thuần Gini (Gini Impurity):

> Gini(D) = 1 - (p_0^2 + p_1^2)

Để ngăn chặn hiện tượng quá khớp (Overfitting – khi cây phân nhánh quá sâu để cố gắng khớp từng điểm nhiễu), nhóm tiến hành cắt tỉa cây bằng cách khống chế các siêu tham số: độ sâu tối đa `max_depth`, số lượng mẫu tối thiểu ở nút lá `min_samples_leaf` và số lượng mẫu tối thiểu để phân nhánh `min_samples_split`.

3.1.5. Mô hình tập hợp Bagging: Random Forest

Random Forest khắc phục nhược điểm phương sai cao của Decision Tree bằng kỹ thuật tập hợp **Bagging (Bootstrap Aggregating)** kết hợp không gian ngẫu nhiên (Random Subspace):

1. **Lấy mẫu Bootstrap:** Huấn luyện B cây quyết định độc lập trên B tập dữ liệu con được rút mẫu có hoàn lại từ tập dữ liệu huấn luyện gốc.
2. **Lấy mẫu thuộc tính ngẫu nhiên:** Tại mỗi nút phân nhánh của từng cây, giải thuật chỉ chọn ngẫu nhiên một tập con gồm m ≈ sqrt(d) thuộc tính để tìm phép phân chia tối ưu, giúp các cây không bị tương quan (decorrelation).
3. **Tổng hợp kết quả:** Xác suất rủi ro cuối cùng là trung bình cộng xác suất của toàn bộ B cây:

   > p_hat(x) = (1 / B) × ∑ p_hat_b(x)

Cơ chế này giúp Random Forest giảm thiểu đáng kể phương sai (Variance) mà không làm tăng độ chệch (Bias).

3.1.6. Mô hình học tăng cường Boosting: XGBoost (Extreme Gradient Boosting)

XGBoost là thuật toán học tăng cường dựa trên cây (Tree Boosting) mạnh mẽ và tối tân nhất hiện nay. Thay vì huấn luyện các cây độc lập như Random Forest, XGBoost xây dựng chuỗi các cây tuần tự, trong đó mỗi cây mới được học để bù trừ phần dư sai số (residuals) của toàn bộ các cây trước đó:

> y_hat_i^(t) = y_hat_i^(t-1) + f_t(x_i)

Hàm mục tiêu tại bước thứ t được tối ưu hóa bằng khai triển Taylor bậc hai:

> Obj^(t) ≈ ∑ [g_i f_t(x_i) + 0.5 h_i f_t^2(x_i)] + Ω(f_t)

Trong đó: g_i là gradient bậc nhất, h_i là hessian bậc hai, và Ω(f_t) là hàm phạt mức độ phức tạp của cây (giúp kiểm soát Overfitting).

Đặc biệt, XGBoost hỗ trợ tham số `scale_pos_weight` cho phép nhân trọng số hình phạt đối với việc phân loại sai lớp thiểu số, đồng thời thuật toán xây dựng biểu đồ tần suất `tree_method='hist'` giúp tăng tốc độ huấn luyện lên hàng chục lần trên dữ liệu lớn.

3.2. Phân tích toán học 3 chiến lược giải quyết mất cân bằng dữ liệu

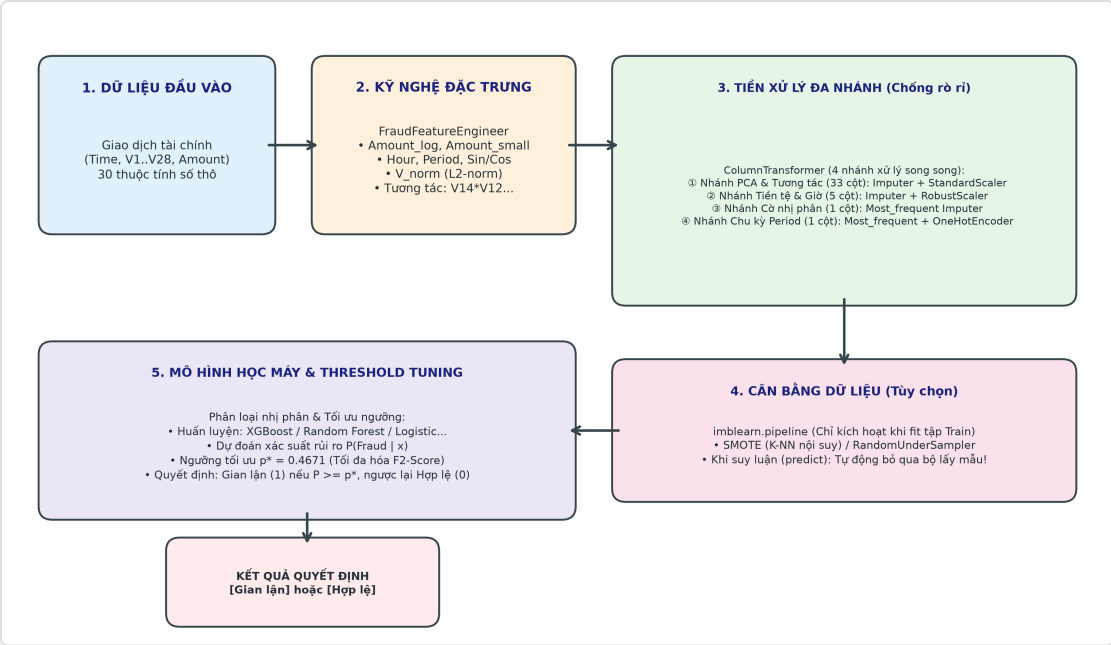
Để đối phó với tỷ lệ mất cân bằng 0,17%, nhóm đã phân tích và thử nghiệm 3 chiến lược kỹ thuật cốt lõi:

Bảng 3.1: So sánh đặc tính lý thuyết và toán học của 3 chiến lược xử lý mất cân bằng

Chiến lược	Nguyên lý toán học	Ưu điểm nổi bật	Nhược điểm & Rủi ro
1. Trọng số lớp (Class Weight)	Gán trọng số nghịch đảo với tần suất xuất hiện vào hàm mất mát: $w_1 = N / (2 \times N_1)$, $w_0 = N / (2 \times N_0)$ với $w_1 \approx 300 \times w_0$. Phạt nặng gấp 300 lần khi đoán sai gian lận.	Không làm thay đổi kích thước hay cấu trúc dữ liệu; Không sinh dữ liệu giả; Tốc độ huấn luyện cực nhanh.	Chỉ áp dụng được cho các mô hình hỗ trợ hàm mất mát có trọng số (Logistic, RF, XGBoost).
2. Tăng mẫu tổng hợp (SMOTE)	Sinh mẫu nhân tạo trong không gian đặc trưng bằng phép nội suy véc-tơ giữa điểm gian lận x và k lân cận cùng lớp: $x_{new} = x + \lambda \times (x_{nn} - x)$, với λ thuộc [0, 1]	Mở rộng vùng biên quyết định cho lớp thiểu số; Tránh lặp lại mẫu đơn thuần như Random Oversampling.	Có thể sinh ra mẫu giả nằm sâu trong vùng an toàn, tạo nhiễu làm tăng số ca báo động nhầm (FP); Tăng kích thước tập train làm chậm quá trình học.
3. Giảm mẫu ngẫu nhiên (Undersampling)	Rút ngẫu nhiên một tập con từ lớp đa số để số lượng mẫu bình thường bằng hoặc gấp vài lần số mẫu gian lận ($N_0' = \alpha \times N_1$).	Giảm kích thước tập dữ liệu xuống hàng trăm lần, giúp các thuật toán nặng như k-NN chạy mượt mà.	Vứt bỏ hơn 95% thông tin hữu ích của lớp đa số, làm tăng nguy cơ suy giảm tính tổng quát hóa của mô hình.

3.3. Thiết kế kiến trúc Pipeline tổng thể với `imblearn`

Để đảm bảo toàn bộ luồng xử lý từ tiền xử lý, kỹ nghệ đặc trưng, cân bằng dữ liệu đến mô hình phân loại được tự động hóa hoàn toàn và **ngăn chặn triệt để rò rỉ dữ liệu**, nhóm sử dụng `imblearn.pipeline.Pipeline`.



Hình 3.1: Sơ đồ kiến trúc luồng dữ liệu khép kín End-to-End của hệ thống phát hiện gian lận

Cơ chế vận hành chống rò rỉ của `imblearn.pipeline`:

- **Trong pha huấn luyện (`pipeline.fit(X_train, y_train)`):** Dữ liệu đi qua `FraudFeatureEngineer` → chuyển qua `ColumnTransformer` (tính toán Median và chuẩn hóa) → bộ lấy mẫu `SMOTE` hoặc `RandomUnderSampler` sinh/giảm mẫu → truyền vào mô hình để học trọng số. Mọi phép học tham số chỉ diễn ra trên phần Train của fold hiện tại.
- **Trong pha dự đoán (`pipeline.predict_proba(X_test)`):** Pipeline **tự động bỏ qua bộ lấy mẫu (Sampler)**! Dữ liệu mới được áp dụng đúng các phép biến đổi đã học từ pha train và đưa thẳng vào mô hình để dự đoán xác suất rủi ro trên phân phối thực tế của thị trường, loại bỏ hoàn toàn nguy cơ sai lệch phân phối.

3.4. Phương pháp luận Đánh giá chéo (5-Fold Stratified Cross-Validation)

Để đánh giá năng lực của các mô hình một cách khách quan, tránh phụ thuộc vào một lần chia dữ liệu may rủi, nhóm thiết lập quy trình **5-Fold Stratified Cross-Validation** chuẩn mực:

1. Tập huấn luyện (226.980 dòng) được chia thành 5 phần (Fold) bằng nhau.
2. Kỹ thuật phân tầng (Stratified) bảo đảm mỗi Fold luôn duy trì chính xác tỷ lệ 0,1665% gian lận (≈ 75 – 76 ca gian lận và ≈ 45.320 ca bình thường trên mỗi Fold).

3. Tại mỗi lượt đánh giá: 4 Fold được dùng làm Train và 1 Fold làm Validation. Quá trình lặp lại 5 lần luân phiên. Mọi bước tiền xử lý và lấy mẫu đều nằm trọn vẹn trong từng vòng lặp.
4. Hiệu năng mô hình được tính bằng trung bình cộng và độ lệch chuẩn của chỉ số **PR-AUC** qua 5 Fold.
5. Tinh chỉnh siêu tham số được thực hiện bài bản bằng `GridSearchCV` (đối với Logistic Regression) và `RandomizedSearchCV` với 50 lần lặp (đối với Decision Tree, Random Forest, XGBoost) với mục tiêu tối ưu hóa trực tiếp chỉ số `scoring='average_precision'` (PR-AUC).

3.5. Phương pháp tối ưu ngưỡng quyết định (Threshold Tuning)

Hầu hết các thư viện học máy đều sử dụng ngưỡng quyết định mặc định p = 0,5 (tức nếu xác suất p_hat ≥ 0,5 thì phân loại là Gian lận). Tuy nhiên, đối với bài toán mất cân bằng tỷ lệ 0,17%, ngưỡng 0,5 là hoàn toàn không tối ưu.

Để tìm ngưỡng tối ưu p*, nhóm trích xuất véc-tơ xác suất dự đoán ngoài tập (Out-Of-Fold Predictions) trên tập Train và thực hiện quét lưới ngưỡng quyết định p thuộc [0,01; 0,99] với bước nhảy 0,001. Tại mỗi ngưỡng p, ma trận nhầm lẫn được tái lập và chỉ số F2-Score được tính toán:

> p* = argmax F2(p) = argmax [5 × Precision(p) × Recall(p) / (4 × Precision(p) + Recall(p))]

Kết quả tối ưu: Ngưỡng quyết định tối ưu tìm được trên mô hình XGBoost là **p* ≈ 0,4671**. Việc điều chỉnh ngưỡng giúp tăng mạnh chỉ số Recall lên trên 85% mà vẫn giữ vững độ chuẩn xác Precision ở mức cao, mang lại giá trị kinh tế thực tế vượt trội cho bài toán kinh doanh thẻ tín dụng.

BIÊN BẢN CHUYỂN GIAO TIẾP TỤC CHO TẬP 2

XÁC NHẬN HOÀN THÀNH PHẦN BÁO CÁO TẬP 1 (ĐỨC ANH PHỤ TRÁCH)

Đến đây, thành viên **Đức Anh** đã hoàn thành trọn vẹn 100% khối lượng biên soạn nội dung Báo cáo Kỹ thuật từ Trang bìa, Bảng phân công nhiệm vụ, Chương 1 (Giới thiệu bài toán & Mục tiêu nghiên cứu), Chương 2 (Khám phá dữ liệu EDA, Tiền xử lý & Kỹ nghệ đặc trưng) đến Chương 3 (Cơ sở thuật toán, Chiến lược cân bằng dữ liệu, Kiến trúc Pipeline & Tối ưu hóa ngưỡng).

Toàn bộ phần mã nguồn, dữ liệu thực nghiệm kiểm chứng, các đồ thị hình học (Hình 2.1 đến 2.9, Hình 3.1) và các bảng số liệu định lượng (Bảng 2.1 đến 2.8, Bảng 3.1) đã được đóng gói đồng bộ, minh bạch và sẵn sàng để chuyển giao cho thành viên **Trần Duy**.

NỘI DUNG TIẾP NỐI Ở TẬP 2 (TRẦN DUY PHỤ TRÁCH):

- **CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM & ĐÁNH GIÁ MÔ HÌNH CHUYÊN SÂU**
    - 4.1. Bảng so sánh định lượng đa chỉ số (PR-AUC, ROC-AUC, Recall, Precision, F1, F2, MCC) của 5 mô hình trên tập Cross-Validation và tập Test độc lập.
    - 4.2. Phân tích đường cong hiệu năng (PR Curve, ROC Curve) và kiểm định Bootstrap Confidence Interval.
    - 4.3. Phân tích ma trận nhầm lẫn (Confusion Matrix) và mổ xẻ chi tiết các ca False Negative (gian lận bị bỏ sót).
    - 4.4. Giải thích mô hình hộp đen bằng XAI: Phân tích tầm quan trọng của đặc trưng qua Permutation Importance và biểu đồ SHAP Summary Plot (Shapley Additive Explanations).
    - 4.5. Đánh giá độ bền vững theo thời gian (Temporal Validation) và phân tích tác động kinh tế (Business Impact / Cost Analysis).
- **CHƯƠNG 5: KẾT LUẬN & HƯỚNG PHÁT TRIỂN**
    - 5.1. Tổng kết các đóng góp kỹ thuật chính của đề tài và kết quả đạt được.
    - 5.2. Các hạn chế còn tồn tại và thách thức triển khai thực tế.
    - 5.3. Định hướng nghiên cứu mở rộng trong tương lai (Học sâu Graph Neural Network, Federated Learning).
- **TÀI LIỆU THAM KHẢO & PHỤ LỤC**

- Danh mục các bài báo khoa học quốc tế (IEEE, ACM, Kaggle, Springer) và tài liệu hướng dẫn chuẩn của HUCE.

NGƯỜI BIÊN SOẠN TẬP 1	**TRƯỞNG NHÓM DUYỆT BÀN GIAO**
(Đã ký xác nhận)	*(Đã ký xác nhận)*
Đức Anh	**Bình**