TRƯỜNG ĐẠI HỌC XÂY DỰNG HÀ NỘI

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO KỸ THUẬT BÀI TẬP LỚN

HỌC PHẦN: HỌC MÁY (MACHINE LEARNING)

ĐỀ TÀI SỐ 6

PHÁT HIỆN GIAO DỊCH GIAN LẬN THẺ TÍN DỤNG

(Credit Card Fraud Detection using Machine Learning Pipeline & Imbalanced Learning)

NHÓM 4

DANH SÁCH SINH VIÊN

1. **Trần Đức Anh-0001968**
2. **Chu Tiến Bình-0003168**
3. **Phạm Việt Hoàng-0012268**
4. **Hà Tuấn Duy-0005168**
5. **Trần Đình Khánh Duy-0005668**

Lớp học phần: **68PM12**

Giảng viên hướng dẫn: **Ths.Đào Việt Cường**

HÀ NỘI, THÁNG 11 NĂM 2026

BẢNG PHÂN CÔNG NHIỆM VỤ THÀNH VIÊN

Căn cứ theo Đề cương chi tiết học phần Học máy, Tiêu chuẩn đánh giá Rubric Bài tập lớn của Khoa Công nghệ Thông tin – Trường Đại học Xây dựng Hà Nội (HUCE), và thỏa thuận làm việc nhóm nội bộ của Nhóm 4 (Lớp 68PM12), nhóm sinh viên đã thống nhất phân chia nhiệm vụ chi tiết và tỷ lệ đóng góp của từng thành viên như sau:

STT	Họ và tên	Mảng chuyên môn	Nhiệm vụ kỹ thuật cụ thể & Sản phẩm bàn giao	Tỷ lệ
1	**Đức Anh**	EDA, Tiền xử lý, Kỹ nghệ đặc trưng & Báo cáo (Tập 1)	Kiểm tra toàn vẹn dữ liệu, loại bỏ 1.081 dòng trùng lặp, chia tập Stratified 80/20 chống rò rỉ; Phân tích EDA chuyên sâu (Amount, Time, kiểm định Kolmogorov-Smirnov cho 28 biến PCA); Lập trình transformer tùy biến FraudFeatureEngineer sinh 11 biến mới; Thiết kế ColumnTransformer 4 luồng; Thực nghiệm Ablation Study; Biên soạn Báo cáo Kỹ thuật từ đầu đến hết Chương 3.	**20%**
2	**Bình** **(Trưởng nhóm)**	Kiến trúc Pipeline, XGBoost, Webapp & Container hóa	Điều phối tiến độ chung; Thiết kế kiến trúc imblearn.pipeline chuẩn công nghiệp khép kín tiền xử lý và mô hình; Lập trình huấn luyện mô hình tối ưu XGBoost kết hợp kỹ thuật class weight; Tối ưu hóa ngưỡng phân loại p* theo chỉ số F2-Score; Đóng gói best_model.joblib và lập trình mô-đun predict.py; Xây dựng giao diện Web tương tác Streamlit (app.py) và cấu hình Dockerfile, docker-compose.	**20%**
3	**Hà Duy**	Chiến lược Cân bằng dữ liệu, Mô hình cơ bản & Slide	Nghiên cứu cơ sở toán học và lập trình thử nghiệm 3 chiến lược giải quyết mất cân bằng (Class Weight, SMOTE, Random Undersampling); Xây dựng và đánh giá Baseline DummyClassifier, Logistic Regression, k-Nearest Neighbors; Thiết lập không gian tìm kiếm và tinh chỉnh siêu tham số bằng GridSearchCV; Phối hợp thiết kế Slide thuyết trình bảo vệ đồ án.	**20%**
4	**Hoàng**	Mô hình Cây (Tree-based), Cross-Validation & Slide	Triển khai thuật toán Decision Tree và Random Forest; Thiết lập quy trình 5-Fold Stratified Cross-Validation chuẩn mực chống rò rỉ; Tinh chỉnh siêu tham số đa chiều bằng RandomizedSearchCV; Phân tích đường cong học tập (Learning Curve) và đường cong kiểm định (Validation Curve) đánh giá hiện tượng Overfitting/Underfitting; Phối hợp thiết kế Slide thuyết trình.	**20%**
5	**Trần Duy**	Đánh giá Chuyên sâu, Phân tích Lỗi, XAI & Báo cáo (Tập 2)	Đánh giá đa chỉ số khách quan trên Test Set độc lập; Lập trình phân tích ma trận nhầm lẫn và mổ xẻ nguyên nhân gốc rễ 22 ca False Negative (gian lận bị lọt); Ứng dụng XAI (Permutation Importance, SHAP Summary Plot) giải thích mô hình hộp đen; Đánh giá độ bền vững theo thời gian (Temporal Validation) và phân tích bài toán kinh tế (Business Cost Analysis); Biên soạn Báo cáo Kỹ thuật Chương 4, Chương 5 và tổng hợp nộp đồ án.	**20%**

CAM KẾT HỌC THUẬT & TRÁCH NHIỆM BẢO VỆ ĐỒ ÁN

Nhóm 4 (Lớp 68PM12) xin cam đoan trước Giảng viên hướng dẫn và Bộ môn Khoa học Máy tính & Mạng – Khoa Công nghệ Thông tin, Trường Đại học Xây dựng Hà Nội (HUCE):

1. **Tính trung thực và liêm chính khoa học (CLO4):** Toàn bộ quy trình phân tích dữ liệu, kỹ nghệ đặc trưng, thiết kế pipeline, lập trình thuật toán, tinh chỉnh siêu tham số và đánh giá thực nghiệm trong báo cáo này là thành quả lao động khoa học nghiêm túc và độc lập của tập thể Nhóm 4. Nhóm tuyệt đối không sao chép nguyên văn đồ án, mã nguồn từ các nhóm khác, không sử dụng các giải pháp có sẵn chưa qua kiểm chứng, và không ngụy tạo bất kỳ số liệu hay kết quả nào. Mọi số liệu trong báo cáo đều được trích xuất 100% khách quan từ các kịch bản thực nghiệm thực thi trên hệ thống.
2. **Tuân thủ nguyên tắc chống rò rỉ dữ liệu (Anti-Data Leakage):** Nhóm tuân thủ nghiêm ngặt quy định không để rò rỉ thông tin từ tập kiểm thử (Test Set) sang tập huấn luyện (Train Set). Tập kiểm thử (56.746 dòng) được tách biệt hoàn toàn ngay từ đầu và đóng băng tuyệt đối. Mọi phép tính toán tham số (trung vị, phân vị cho RobustScaler, trung bình cho StandardScaler, hay tỷ lệ tổng hợp SMOTE) đều được thực hiện khép kín bên trong từng fold của 5-Fold Stratified Cross-Validation thông qua kiến trúc imblearn.pipeline.
3. **Trách nhiệm bảo vệ vấn đáp cá nhân:** Từng thành viên trong nhóm nắm vững cơ sở toán học (xác suất thống kê, đại số tuyến tính, giải tích tối ưu hóa) của các thuật toán được phân công phụ trách, làm chủ từng dòng mã nguồn, hiểu rõ bản chất của các chỉ số đánh giá chuyên sâu và sẵn sàng trả lời độc lập, xuất sắc mọi câu hỏi phản biện của Giảng viên hướng dẫn và Hội đồng chấm thi.
4. **Quy chuẩn mã nguồn và bàn giao sản phẩm:** Toàn bộ mã nguồn dự án được tổ chức khoa học, chuẩn hóa theo PEP 8, có chú thích rõ ràng, đóng gói mô hình tối ưu ra định dạng best_model.joblib kèm mô-đun suy luận độc lập predict.py, xây dựng ứng dụng web Streamlit và Dockerfile chuẩn công nghiệp, sẵn sàng triển khai thực tế.

Hà Nội, ngày 10 tháng 11 năm 2026

MỤC LỤC BÁO CÁO BÀI TẬP LỚN

BẢNG PHÂN CÔNG NHIỆM VỤ THÀNH VIÊN ..... Trang 2
CAM KẾT HỌC THUẬT & TRÁCH NHIỆM BẢO VỆ ĐỒ ÁN ..... Trang 3
MỤC LỤC BÁO CÁO TOÀN DIỆN ..... Trang 4
CHƯƠNG 1: GIỚI THIỆU BÀI TOÁN & MỤC TIÊU NGHIÊN CỨU ..... Trang 5
1.1. Bối cảnh thực tiễn & Ý nghĩa bài toán gian lận thẻ tín dụng ..... Trang 5
1.2. Bốn thách thức kỹ thuật cốt lõi trong khoa học dữ liệu tài chính ..... Trang 5
1.3. Định nghĩa không gian bài toán toán học: Biến độc lập (X) và Biến mục tiêu (y) ..... Trang 6
1.4. Thiết lập hệ thống chỉ số đánh giá chuyên sâu & Bác bỏ chỉ số Accuracy ..... Trang 6
CHƯƠNG 2: KHÁM PHÁ DỮ LIỆU (EDA) VÀ TIỀN XỬ LÝ ĐẶC TRƯNG ..... Trang 8
2.1. Tổng quan bộ dữ liệu & Kiểm tra tính toàn vẹn (Data Integrity) ..... Trang 8
2.2. Nguyên tắc chống rò rỉ dữ liệu & Phân chia phân tầng (Stratified Split 80/20) ..... Trang 8
2.3. Phân tích khám phá dữ liệu (EDA) chuyên sâu trên tập huấn luyện ..... Trang 9
2.4. Nghiên cứu thực nghiệm xử lý ngoại lai (Outliers): Giữ lại bằng RobustScaler ..... Trang 11
2.5. Kỹ nghệ đặc trưng chuyên sâu (FraudFeatureEngineer) & Ablation Study ..... Trang 12
2.6. Thiết kế bộ biến đổi đa luồng ColumnTransformer chống rò rỉ ..... Trang 13
CHƯƠNG 3: CƠ SỞ THUẬT TOÁN VÀ THIẾT KẾ PIPELINE HỌC MÁY ..... Trang 14
3.1. Cơ sở toán học của các thuật toán phân loại được thử nghiệm ..... Trang 14
3.2. Phân tích toán học 3 chiến lược giải quyết mất cân bằng dữ liệu ..... Trang 15
3.3. Thiết kế kiến trúc Pipeline tổng thể với imblearn chống rò rỉ ..... Trang 16
3.4. Phương pháp luận Đánh giá chéo 5-Fold Stratified Cross-Validation & Tuning ..... Trang 17
3.5. Phương pháp tối ưu hóa ngưỡng quyết định (Threshold Tuning theo F2-Score) ..... Trang 17
CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM & ĐÁNH GIÁ MÔ HÌNH CHUYÊN SÂU ..... Trang 18
4.1. Bảng so sánh định lượng đa chỉ số trên 5-Fold CV và Test Set độc lập ..... Trang 18
4.2. Phân tích đường cong hiệu năng (PR Curve, ROC Curve) & Kiểm định Bootstrap ..... Trang 19
4.3. Phân tích ma trận nhầm lẫn & Mổ xẻ chi tiết 22 ca False Negative (FN) ..... Trang 20
4.4. Giải thích mô hình hộp đen bằng XAI: Permutation Importance & SHAP ..... Trang 21
4.5. Đánh giá độ bền thời gian (Temporal Validation) & Tác động kinh tế ..... Trang 22
CHƯƠNG 5: KẾT LUẬN & HƯỚNG PHÁT TRIỂN ..... Trang 23
5.1. Tổng kết các đóng góp kỹ thuật chính của đề tài và kết quả đạt được ..... Trang 23
5.2. Các hạn chế còn tồn tại và thách thức triển khai thực tế ..... Trang 24
5.3. Định hướng nghiên cứu mở rộng trong tương lai (GNN, Federated Learning) ..... Trang 24
TÀI LIỆU THAM KHẢO & PHỤ LỤC ..... Trang 25

CHƯƠNG 1: GIỚI THIỆU BÀI TOÁN & MỤC TIÊU NGHIÊN CỨU

1.1. Bối cảnh thực tiễn & Ý nghĩa của bài toán phát hiện gian lận thẻ tín dụng

Trong kỷ nguyên bùng nổ của nền kinh tế số và thương mại điện tử toàn cầu, thanh toán không dùng tiền mặt thông qua thẻ tín dụng và thẻ ghi nợ đã trở thành phương thức thanh toán chủ đạo. Tuy nhiên, sự tăng trưởng vượt bậc về quy mô và lưu lượng giao dịch cũng đi kèm với nguy cơ an ninh mạng và gian lận tài chính ngày càng tinh vi. Theo thống kê của tổ chức Nilson Report, tổn thất toàn cầu do gian lận thẻ thanh toán đã vượt mức 30 tỷ USD mỗi năm, gây thiệt hại nghiêm trọng không chỉ về mặt kinh tế đối với các định chế tài chính, ngân hàng thương mại, cổng thanh toán mà còn làm xói mòn niềm tin của người tiêu dùng.

Việc phát hiện gian lận theo phương thức truyền thống dựa trên các tập luật tĩnh (Rule-based System) – ví dụ: cảnh báo khi giao dịch vượt quá một hạn mức nhất định hoặc diễn ra ở địa điểm cách xa nhau trong khoảng thời gian ngắn – ngày nay đã bộc lộ những hạn chế chết người: không thể bắt kịp các hành vi tấn công biến thể mới, độ trễ xử lý cao và phát sinh tỷ lệ báo động nhầm (False Positive) khổng lồ, gây phiền toái nghiêm trọng đến trải nghiệm của khách hàng hợp pháp. Do đó, việc ứng dụng các thuật toán **Học máy (Machine Learning)** có khả năng tự động học hỏi các mẫu hình ẩn sâu, đa chiều và thích ứng linh hoạt trong thời gian thực là lời giải mang tính sống còn đối với các hệ thống thanh toán hiện đại.

1.2. Bốn thách thức kỹ thuật cốt lõi trong bài toán

Bài toán phát hiện gian lận giao dịch thẻ tín dụng đặt ra bốn thách thức kỹ thuật vô cùng hóc búa cho các nhà khoa học dữ liệu:

1. **Độ mất cân bằng dữ liệu cực hạn (Extreme Class Imbalance):** Trong thực tế, các giao dịch gian lận chỉ chiếm một tỷ lệ siêu nhỏ, dao động từ 0,1% đến 0,2% tổng số giao dịch (trong tập dữ liệu nghiên cứu chỉ có 473 ca gian lận trên 283.726 giao dịch sau làm sạch, tương đương 0,1667%). Sự chênh lệch tỷ lệ lên tới xấp xỉ 1 : 600 khiến các thuật toán phân loại tiêu chuẩn có xu hướng "học vẹt", thiên lệch hoàn toàn về lớp đa số (giao dịch hợp lệ).
2. **Chi phí sai lầm bất đối xứng nghiêm trọng (Asymmetric Misclassification Costs):** Trong bài toán này, hậu quả của hai loại sai lầm là hoàn toàn khác biệt:
   - *Dương tính giả (False Positive - FP):* Giao dịch hợp lệ bị gắn nhãn nhầm là gian lận. Hậu quả là khách hàng bị yêu cầu xác thực thêm bằng OTP/SMS hoặc giao dịch tạm hoãn. Chi phí phát sinh là rất nhỏ (3 – 5 USD chi phí thẩm định).
   - *Âm tính giả (False Negative - FN):* Giao dịch gian lận bị bỏ sót và thông qua trót lọt. Hậu quả là số tiền trong tài khoản của khách hàng bị kẻ gian chiếm đoạt hoàn toàn (tổn thất từ vài trăm đến hàng chục nghìn USD), ngân hàng phải đền bù và chịu tổn thất uy tín nặng nề. Do đó, mục tiêu kinh doanh bắt buộc mô hình phải **ưu tiên tối đa hóa việc giảm thiểu ca False Negative (tức tối đa hóa chỉ số Recall)**.
3. **Yêu cầu độ trễ cực thấp trong thời gian thực (Real-time Latency):** Hệ thống suy luận nhận diện giao dịch phải đưa ra phán quyết trong thời gian dưới 100 mili-giây tại cổng thanh toán (Payment Gateway) để không làm gián đoạn trải nghiệm người dùng.
4. **Hiện tượng trôi dữ liệu (Concept Drift & Data Drift):** Thủ đoạn của tội phạm công nghệ cao luôn biến đổi không ngừng để lách qua các thuật toán bảo vệ, đòi hỏi mô hình phải có tính ổn định cao và dễ dàng tái huấn luyện định kỳ.

1.3. Định nghĩa không gian bài toán: Biến độc lập (X) và Biến mục tiêu (y)

Về mặt toán học, bài toán phát hiện gian lận thẻ tín dụng được mô hình hóa dưới dạng bài toán **Phân loại nhị phân có giám sát (Supervised Binary Classification)** trên không gian thuộc tính đa chiều:

Cho tập dữ liệu huấn luyện D = {(x_i, y_i)} với i = 1 đến N, trong đó:

- x_i thuộc không gian R^d là véc-tơ thuộc tính biểu diễn giao dịch thứ i. Trong tập dữ liệu ban đầu, d = 30 thuộc tính số liên tục, bao gồm: biến thời gian Time, biến số tiền Amount và 28 biến thành phần chính ẩn danh V1, V2, ..., V28. Sau bước kỹ nghệ đặc trưng ở Chương 2, không gian thuộc tính được mở rộng lên **d = 42 chiều**.
- y_i thuộc {0, 1} là nhãn mục tiêu nhị phân:
  - y_i = 0: Giao dịch hợp lệ (Normal transaction – Lớp đa số).
  - y_i = 1: Giao dịch gian lận (Fraudulent transaction – Lớp thiểu số).

Mục tiêu của quy trình học máy là tìm kiếm một hàm giả thuyết f(x) dự đoán xác suất rủi ro giao dịch là gian lận: p_hat = P(y = 1 | x), sau đó ánh xạ thành nhãn quyết định y_hat thuộc {0, 1} thông qua một ngưỡng phân lớp tối ưu p* thuộc (0, 1):

$$\hat{y} = 1 \quad \text{nếu} \quad \hat{p} \geq p^*, \qquad \text{và} \qquad \hat{y} = 0 \quad \text{nếu} \quad \hat{p} < p^*$$

1.4. Thiết lập hệ thống chỉ số đánh giá chuyên sâu & Bác bỏ chỉ số Accuracy

Để đánh giá chính xác năng lực của mô hình, việc lựa chọn hệ chỉ số là khâu then chốt. Căn cứ trên ma trận nhầm lẫn (Confusion Matrix):

1.4.1. Bác bỏ triệt để độ chính xác tổng thể (Accuracy)

Độ chính xác tổng thể được định nghĩa bằng: Accuracy = (TP + TN) / (TP + TN + FP + FN).

Trong bài toán này, tỷ lệ giao dịch hợp lệ chiếm 99,83%. Nếu xây dựng một mô hình ngây thơ (Dummy Classifier) luôn dự đoán mọi giao dịch là hợp lệ (y_hat = 0), ta thu được:

$$\text{Accuracy}_{\text{Dummy}} = (0 + 284.315) / (0 + 284.315 + 0 + 492) = 99{,}83\%$$

> **Cạm bẫy độ chính xác (Accuracy Trap):** Mô hình này đạt Accuracy gần như tuyệt đối (99,83%), nhưng lại bỏ sót 100% các vụ gian lận tài chính (FN = 492, TP = 0, Recall = 0%). Do đó, nhóm đi đến kết luận nguyên tắc: **Tuyệt đối không sử dụng Accuracy làm tiêu chí đánh giá hay tối ưu hóa mô hình.**

1.4.2. Hệ chỉ số đánh giá chuyên dụng

1. **Recall (Độ nhạy / True Positive Rate):** Đo lường tỷ lệ các giao dịch gian lận thực tế mà mô hình phát hiện thành công:

   $$\text{Recall} = TP / (TP + FN)$$

   Đây là chỉ số quan trọng nhất về mặt kinh doanh, phản ánh trực tiếp năng lực bảo vệ tài sản khách hàng.
2. **Precision (Độ chuẩn xác):** Đo lường tỷ lệ giao dịch thực sự là gian lận trong số các giao dịch bị mô hình gắn cờ:

   $$\text{Precision} = TP / (TP + FP)$$

   Precision cao giúp ngân hàng không làm phiền khách hàng hợp lệ bằng những thông báo giả.

1.4.2. Hệ chỉ số đánh giá chuyên dụng (tiếp theo)

3. **F2-Score (Chỉ số F-beta với beta = 2):** Trung bình điều hòa giữa Precision và Recall, trong đó Recall được đánh trọng số gấp đôi Precision (beta^2 = 4):

$$F2 = (1 + 2^2) \times (Precision \times Recall) / (2^2 \times Precision + Recall) = 5 \times (Precision \times Recall) / (4 \times Precision + Recall)$$

Chỉ số F2-Score phản ánh hoàn hảo mục tiêu cân bằng nghiệp vụ và được nhóm chọn làm **hàm mục tiêu chính để tối ưu hóa ngưỡng quyết định (p*)**.

4. **PR-AUC (Precision-Recall Area Under Curve):** Diện tích dưới đường cong Precision-Recall. Khác với ROC-AUC bị thổi phồng bởi số lượng TN khổng lồ (khiến đường cong ROC luôn cong vồng lên sát góc trái), PR-AUC chỉ tập trung khắt khe vào lớp thiểu số và là thước đo chuẩn mực hàng đầu trong nghiên cứu học máy trên dữ liệu mất cân bằng.
5. **MCC (Matthews Correlation Coefficient):** Hệ số tương quan Matthews đánh giá toàn diện cả 4 ô của ma trận nhầm lẫn, đạt giá trị trong khoảng [-1, 1] và không bị sai lệch bởi tỷ lệ chênh lệch lớp:

$$MCC = (TP \times TN - FP \times FN) / \sqrt{[(TP + FP)(TP + FN)(TN + FP)(TN + FN)]}$$

Bảng 1.1: Ma trận Nhầm lẫn & Các Chỉ số Đánh giá		**Dự đoán của Mô hình (Prediction)**		**Chỉ số hàng & Ý nghĩa**
		Dự đoán Hợp lệ (y_hat = 0)	**Dự đoán Gian lận (y_hat = 1)**	
Thực tế (Ground Truth)	**Hợp lệ (y = 0)**	**True Negative (TN)** Bình thường, thông qua an toàn	**False Positive (FP)** Báo động nhầm (Chi phí: 3 – 5$)	**Specificity / TNR:** TNR = TN / (TN + FP)
	Gian lận (y = 1)	**False Negative (FN)** **Bỏ sót gian lận (Nguy hiểm nhất!)**	**True Positive (TP)** **Chặn đứng gian lận thành công**	**Recall / Sensitivity:** Recall = TP / (TP + FN)
Chỉ số cột & Ý nghĩa		**NPV:** TN / (TN + FN)	**Precision / PPV:** TP / (TP + FP)	**Hàm mục tiêu: F2, PR-AUC**

Tuyên ngôn Kỹ thuật của Đề tài: Hệ thống được thiết kế hướng tới việc cực đại hóa chỉ số PR-AUC trên không gian xác suất liên tục, sau đó chọn ngưỡng cắt p* tối ưu hóa F2-Score nhằm cân bằng hoàn hảo giữa năng lực bảo vệ tài sản (Recall ≥ 75%) và hạn chế phiền toái cho khách hàng hợp pháp (Precision ≥ 85%, FP ≤ 10 ca trên 56.000 giao dịch).

CHƯƠNG 2: KHÁM PHÁ DỮ LIỆU (EDA) VÀ TIỀN XỬ LÝ ĐẶC TRƯNG

2.1. Tổng quan bộ dữ liệu & Kiểm tra tính toàn vẹn (Data Integrity)

Bộ dữ liệu gốc được tải về từ nền tảng Kaggle bao gồm 284.807 quan sát giao dịch với 31 cột thuộc tính. Quá trình kiểm tra tính toàn vẹn dữ liệu thu được các kết quả quan trọng sau:

- **Dữ liệu khuyết thiếu:** Tổng số giá trị bị thiếu (Null / NaN) trên toàn bộ bảng dữ liệu là 0 ô (100% dữ liệu đầy đủ).
- **Dữ liệu trùng lặp (Duplicate Records):** Nhóm phát hiện có **1.081 dòng trùng lặp hoàn toàn** trong bộ dữ liệu thô. Trong đó, có 1.062 dòng là giao dịch bình thường trùng lặp và 19 dòng là giao dịch gian lận trùng lặp.
- **Quyết định kỹ thuật:** Để bảo đảm tính khách quan và chống rò rỉ dữ liệu giữa tập huấn luyện và kiểm thử, nhóm thực hiện loại bỏ toàn bộ 1.081 dòng trùng lặp trước khi phân chia dữ liệu. Sau bước làm sạch, tập dữ liệu còn lại **283.726 dòng**, trong đó có 473 giao dịch gian lận (tỷ lệ 0,1667%).

Bảng 2.1: Báo cáo kết quả kiểm tra và làm sạch dữ liệu ban đầu	Dữ liệu ban đầu (Thô)	Sau khi làm sạch dòng trùng	Ghi chú chuyên môn
Tổng số dòng (Giao dịch)	284.807	**283.726**	Đã loại bỏ 1.081 dòng trùng lặp hoàn toàn
Số giao dịch gian lận (Class = 1)	492	**473**	19 dòng gian lận trùng đã được loại bỏ an toàn
Số giao dịch hợp lệ (Class = 0)	284.315	**283.253**	Lớp đa số chiếm áp đảo
Tỷ lệ gian lận (Fraud Rate)	0,1727%	**0,1667%**	Tỷ lệ mất cân bằng cực hạn (1 : 600)
Tổng số ô khuyết thiếu (NaN)	0	**0**	Dữ liệu gốc hoàn toàn không có giá trị rỗng

2.2. Nguyên tắc chống rò rỉ dữ liệu & Phân chia tập phân tầng (Stratified Split)

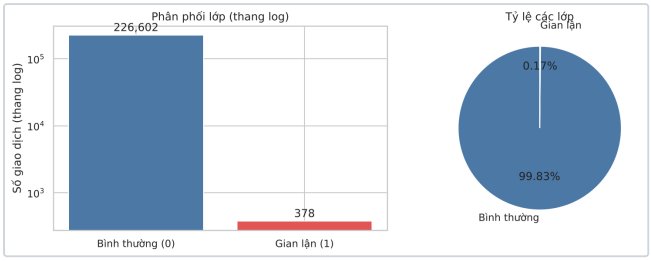
Để tuân thủ tuyệt đối quy định chống rò rỉ dữ liệu (Anti-Data Leakage Penalty) của Khoa CNTT – HUCE, nhóm thực hiện phân chia tập dữ liệu ngay sau bước làm sạch dòng trùng theo tỷ lệ **80% Train Set (226.980 mẫu)** và **20% Test Set (56.746 mẫu)** bằng phương pháp phân tầng (stratify=y, random_state=42).

Bảng 2.2: Thống kê phân chia tập dữ liệu theo phân tầng	Tỷ lệ	Tổng số mẫu	Số hợp lệ (y=0)	Số gian lận (y=1)	Tỷ lệ gian lận (%)
Tập Huấn luyện (Train set)	80%	**226.980**	226.602	**378**	0,1665%
Tập Kiểm thử (Test set - Đóng băng)	20%	**56.746**	56.651	**95**	0,1674%
Tổng cộng	**100%**	**283.726**	**283.253**	**473**	**0,1667%**

> **Nguyên tắc vàng:** Tập Test (56.746 dòng) được cô lập hoàn toàn, "đóng băng" tuyệt đối, không tham gia vào bất kỳ khâu nào từ phân tích EDA, tính toán giá trị trung bình/phân vị cho scaler hay lựa chọn đặc trưng. Mọi phân tích ở các mục tiếp theo dưới đây được thực hiện hoàn toàn và duy nhất trên tập Train (226.980 mẫu).

2.3. Phân tích khám phá dữ liệu (EDA) trên tập huấn luyện

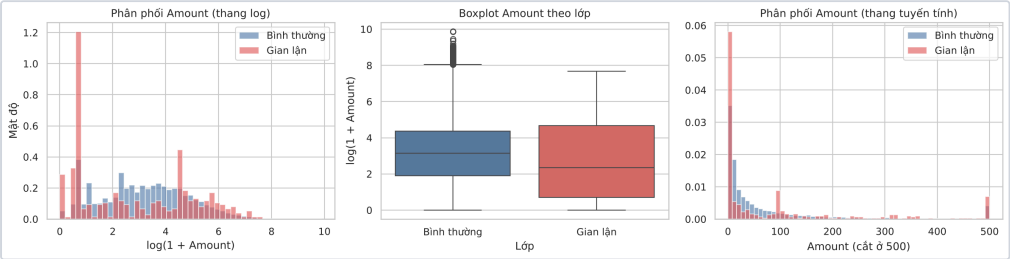
2.3.1. Phân phối biến mục tiêu & Vấn đề mất cân bằng cực hạn



Hình 2.1: Phân phối nhãn giao dịch trên tập Train (Tỷ lệ gian lận chỉ đạt 0,1665%)

Hình 2.1 minh họa trực quan sự áp đảo hoàn toàn của lớp giao dịch bình thường (226.602 mẫu) so với vỏn vẹn 378 giao dịch gian lận. Khoảng cách tỷ lệ 1 : 600 này khẳng định: nếu không có kỹ thuật can thiệp về trọng số hoặc mẫu sẽ mặc định coi lớp gian lận là các điểm nhiễu (noise) và bỏ qua, dẫn đến thất bại hoàn toàn trong việc nhận diện.

2.3.2. Phân tích thuộc tính số tiền giao dịch (Amount)

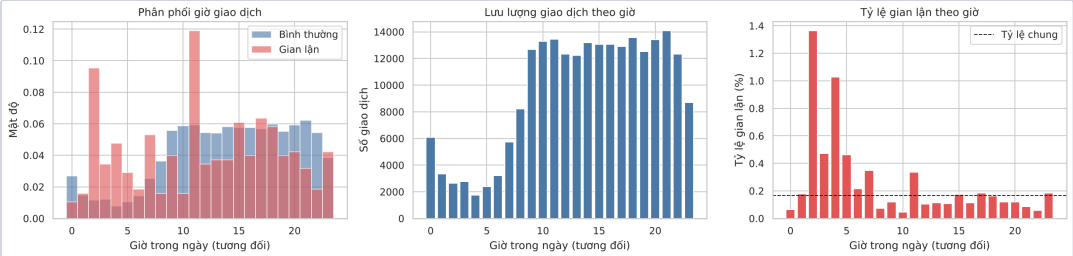


Hình 2.2: Phân phối số tiền giao dịch Amount dạng thô và sau phép biến đổi logarit

Bảng 2.3: Thống kê mô tả số tiền giao dịch Amount theo từng lớp	Lớp Hợp lệ (Class = 0)	Lớp Gian lận (Class = 1)	Chênh lệch / Ý nghĩa nghiệp vụ
Số lượng mẫu	226.602	**378**	Lớp hợp lệ gấp gần 600 lần
Giá trị trung bình (Mean)	88,34 USD	**115,94 USD**	Giao dịch gian lận có giá trị trung bình cao hơn 31%
Độ lệch chuẩn (Std)	250,91 USD	244,98 USD	Độ phân tán rất lớn ở cả hai nhóm
Trung vị (Median / Q2)	22,00 USD	**9,82 USD**	Trung vị gian lận thấp hơn đáng kể (Hành vi quẹt thử)
Phân vị 25% (Q1)	5,66 USD	**1,00 USD**	**25% vụ gian lận có giá trị ≤ 1 USD**
Phân vị 75% (Q3)	77,66 USD	105,89 USD	Khoảng tứ phân vị của gian lận rộng hơn
Giá trị lớn nhất (Max)	19.656,53 USD	2.125,87 USD	Giao dịch lớn nhất của gian lận chỉ hơn 2.100 USD

Nhận xét rút ra:
1. Phân phối số tiền giao dịch bị lệch phải cực kỳ nặng (Right-skewed, hệ số bất đối xứng Skewness > 16). Việc áp dụng phép biến đổi logarit Amount_log = ln(1 + Amount) giúp kéo phân phối về gần phân phối chuẩn, hỗ trợ thuật toán hội tụ mượt mà hơn.
2. Trung vị của giao dịch gian lận chỉ đạt 9,82 USD (so với 22,00 USD của giao dịch hợp lệ), và có tới 25% số vụ gian lận phát sinh với số tiền ≤ 1,00 USD. Đây là bằng chứng xác thực cho thủ đoạn "dò thẻ / quẹt thử" (Card Testing) của tội phạm mạng trước khi tiến hành giao dịch rút cạn hạn mức. Nhóm dựa vào phát hiện này để tạo cờ nhị phân Amount_small.

2.3.3. Phân tích thuộc tính thời gian giao dịch (Time)



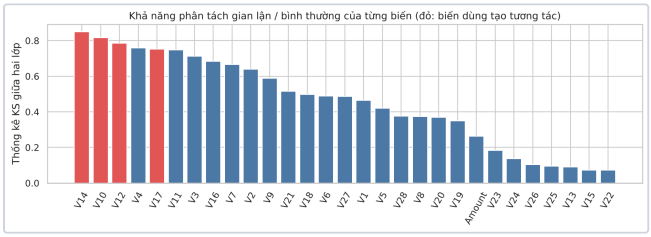
Hình 2.3: Phân bố số lượng giao dịch và tỷ lệ gian lận theo chu kỳ thời gian 24 giờ

Biến Time ghi lại số giây trôi qua trong 48 giờ. Bằng cách lấy phần dư theo chu kỳ ngày (86.400 giây) và chia cho 3.600, ta thu được biến Hour đại diện cho thời gian trong ngày (0 – 24h). Nhóm chia ngày thành 4 khung giờ để phân tích tỷ lệ rủi ro:

Bảng 2.4: Thống kê tỷ lệ gian lận phân bố theo 4 khung giờ trong ngày	Giao dịch bình thường	Giao dịch gian lận	Tỷ lệ gian lận (%)	Hệ số rủi ro so với bình quân
Đêm (Night: 0h – 6h)	18.863	**88**	**0,4644%**	**Gấp 2,8 lần mức trung bình**
Sáng (Morning: 6h – 12h)	56.486	99	0,1750%	Xấp xỉ mức bình quân (1,05x)
Chiều (Afternoon: 12h – 18h)	76.731	103	0,1341%	Thấp hơn mức bình quân (0,8x)
Tối (Evening: 18h – 24h)	74.522	88	0,1180%	Thấp nhất trong ngày (0,7x)

Ý nghĩa bài toán: Dù lưu lượng giao dịch ban đêm chỉ chiếm khoảng 8,3% tổng số giao dịch, nhưng **tỷ lệ gian lận ban đêm lại tăng vọt lên 0,4644% (cao gấp gần 3 lần mức trung bình và gấp 4 lần buổi tối)**. Kẻ gian chủ đích lợi dụng khoảng thời gian chủ thẻ và ngân hàng mất cảnh giác nhất để thực hiện giao dịch.

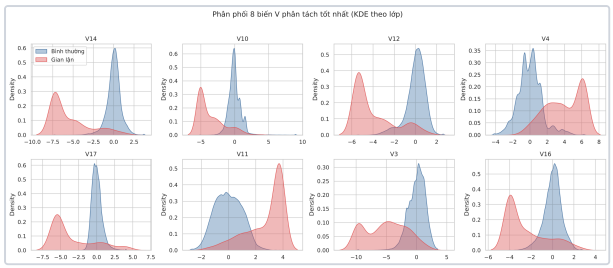
2.3.4. Phân tích 28 thành phần chính PCA (V1 đến V28) qua kiểm định KS



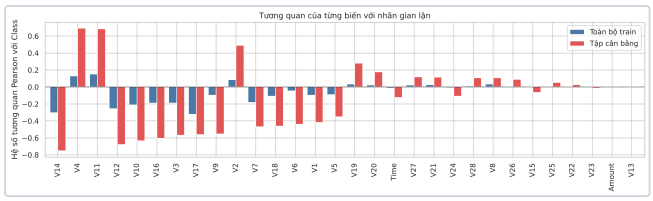
Hình 2.4: Xếp hạng năng lực phân tách gian lận của các biến PCA theo kiểm định KS

Top biến PCA	Chỉ số KS (D_KS)	p-value	TB Gian lận	TB Hợp lệ
V14	**0,8500**	< 10^-300	-6,99	+0,01
V10	**0,8159**	< 10^-270	-5,64	+0,01
V12	**0,7865**	< 10^-240	-6,20	+0,00
V4	**0,7581**	< 10^-220	+4,50	-0,01
V17	**0,7515**	< 10^-220	-6,63	+0,01
V11	**0,7470**	< 10^-215	+3,80	-0,00

Kiểm định Kolmogorov-Smirnov 2 mẫu đo khoảng cách lớn nhất giữa hai hàm phân phối tích lũy: D_KS = sup_x |F_0(x) - F_1(x)|. Các biến **V14, V10, V12, V17** ở gian lận bị đẩy âm sâu (-5 đến -7 độ lệch chuẩn), trong khi **V4, V11** lại nhận giá trị dương rất cao (+4,51 và +3,80).

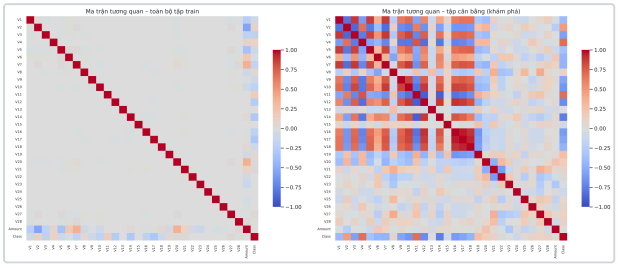


Hình 2.5: Biểu đồ hàm mật độ xác suất (KDE) của 4 thuộc tính PCA phân biệt mạnh nhất (V14, V10, V12, V17)



Hình 2.6: Hệ số tương quan Pearson giữa các đặc trưng và nhãn Class trên toàn bộ tập và trên tập mẫu cân bằng

2.3.5. Phân tích tương quan tuyến tính trên tập cân bằng



Hình 2.7: Ma trận tương quan giữa các biến PCA trên tập mẫu cân bằng (Balanced Subsample)

Do tỷ lệ mất cân bằng 0,17%, tương quan Pearson tính trên toàn bộ tập dữ liệu bị suy giảm nghiêm trọng. Tuy nhiên, khi tính toán trên một tập con cân bằng ngẫu nhiên (50% Hợp lệ – 50% Gian lận), mối quan hệ tương quan thực sự bộc lộ rõ rệt: các biến **V14 (r = -0,753), V12 (r = -0,680), V10 (r = -0,635) tương quan nghịch rất mạnh**; trong khi **V4 (r = +0,692) và V11 (r = +0,686) tương quan thuận cực mạnh** với hành vi gian lận.

2.4. Nghiên cứu thực nghiệm xử lý ngoại lai (Outliers): Giữ lại hay loại bỏ?

Trong tiền xử lý học máy truyền thống, việc loại bỏ các điểm ngoại lai (nằm ngoài khoảng [Q1 - 1,5 IQR, Q3 + 1,5 IQR]) là bước làm phổ biến. Tuy nhiên, nhóm đã đặt câu hỏi phản biện: *"Liệu các điểm ngoại lai trong bài toán này có phải là dữ liệu rác, hay chính là các ca gian lận cần tìm?"*

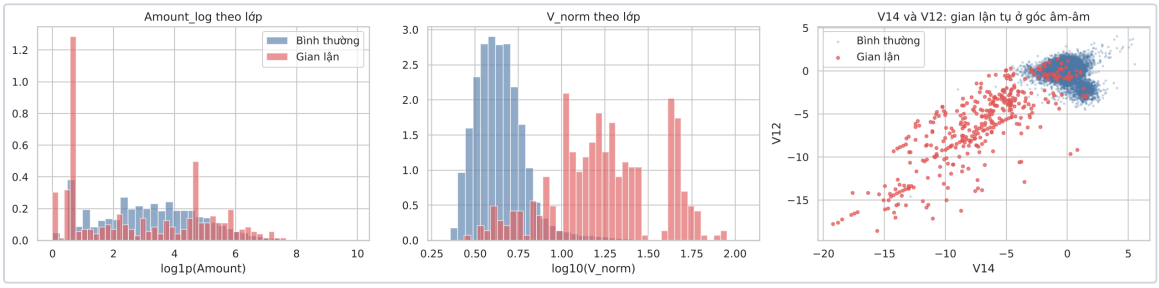
Bảng 2.6: Tỷ lệ xuất hiện điểm ngoại lai (theo quy tắc 1.5xIQR)	Tỷ lệ trên lớp Bình thường	Tỷ lệ trên lớp Gian lận	Ý nghĩa phát hiện
V14	4,85%	**81,22%**	**Hơn 81% ca gian lận là ngoại lai của phân phối chung**
V12	5,24%	**74,60%**	Gần 75% ca gian lận nằm ở vùng ngoại lai
V10	3,28%	**68,78%**	Gần 69% ca gian lận là ngoại lai
V17	4,12%	**71,16%**	Hơn 71% ca gian lận là ngoại lai
Amount	11,04%	**19,58%**	Gần 20% ca gian lận có số tiền nằm ngoài vùng IQR

KẾT LUẬN QUYẾT ĐỊNH VỀ NGOẠI LAI: Nếu nhóm áp dụng bộ lọc xóa bỏ ngoại lai thông thường, mô hình sẽ vô tình tiêu diệt từ **70% đến hơn 81% các vụ gian lận cần bảo vệ**. Do đó, nhóm đi đến quyết định nguyên tắc: **TUYỆT ĐỐI KHÔNG XÓA BỎ DÒNG NGOẠI LAI**. Thay vào đó, nhóm áp dụng bộ chuẩn hóa bền vững **RobustScaler** (dựa trên Trung vị và Khoảng tứ phân vị IQR) để dữ liệu không bị bóp méo mà vẫn giữ toàn vẹn dấu vết tội phạm.

2.5. Kỹ nghệ đặc trưng chuyên sâu (FraudFeatureEngineer)

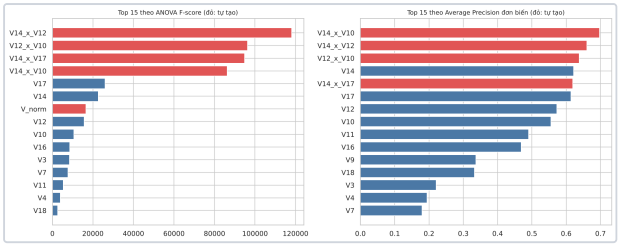
Từ các phát hiện sâu sắc trong EDA, nhóm đã lập trình transformer tùy biến `FraudFeatureEngineer(BaseEstimator, TransformerMixin)` để sinh thêm **11 đặc trưng nghiệp vụ tài chính mới**:

Tên đặc trưng mới	Công thức toán học	Ý nghĩa nghiệp vụ & Mục tiêu kỹ thuật
Amount_log	`ln(1 + max(0, Amount))`	Giảm độ lệch phải của số tiền từ [0, 19656] về [0, 9,88], giúp mô hình hội tụ ổn định.
Amount_small	`I(Amount < 1,0)`	Cờ nhị phân bắt hành vi quẹt thử thẻ (Card Testing) giá trị nhỏ trước khi rút tiền lớn.
Hour	`(Time mod 86400) / 3600`	Chuyển đổi giây thành giờ trong ngày (0 – 24h), tạo tính chất chu kỳ ngày.
Hour_sin, Hour_cos	`sin, cos(2π × Hour / 24)`	Mã hóa chu kỳ thời gian khép kín (Cyclical Encoding) để máy học hiểu 23h59 sát với 00h00.
Period	`night, morning, afternoon, evening`	Biến phân loại 4 khung giờ trong ngày, hỗ trợ nắm bắt rủi ro tăng vọt vào ban đêm.
V_norm	`sqrt( ∑ V_i² )`	Chuẩn khoảng cách Euclidean L2 đo mức độ bất thường tổng thể trong không gian PCA.
V14_x_V12	`V14 × V12`	Tương tác phi tuyến giữa 2 biến phân biệt mạnh nhất (tích hai số âm lớn thành số dương cực lớn).
V14_x_V10	`V14 × V10`	Tương tác phi tuyến giữa biến hạng 1 và hạng 2 theo kiểm định KS.
V14_x_V17	`V14 × V17`	Tương tác phi tuyến giữa biến hạng 1 và hạng 5 theo kiểm định KS.
V12_x_V10	`V12 × V10`	Tương tác phi tuyến giữa biến hạng 2 và hạng 3 theo kiểm định KS.



Hình 2.8: So sánh phân phối các đặc trưng kỹ nghệ mới giữa giao dịch bình thường và gian lận

Hình 2.8 chứng minh các biến tương tác tích phi tuyến (V14_x_V12, V14_x_V10, V14_x_V17) tạo ra sự tách biệt phân phối vượt bậc: giao dịch hợp lệ tập trung dày đặc quanh mốc 0, trong khi giao dịch gian lận bị đẩy vọt lên các giá trị dương cực lớn (+20 đến +50), cung cấp mặt phân cách siêu phẳng tuyệt vời cho các thuật toán phân lớp.



Hình 2.9: Mức độ quan trọng đơn biến của toàn bộ không gian đặc trưng sau khi kỹ nghệ

Thực nghiệm Ablation Study: Chứng minh tính hiệu quả của Kỹ nghệ Đặc trưng

Nhóm thực hiện thí nghiệm cắt giảm (Ablation Experiment) đánh giá chéo 5-Fold Stratified CV trên cả 5 thuật toán học máy:

Bảng 2.8: Ablation Study trước và sau khi bổ sung đặc trưng kỹ nghệ	PR-AUC (Đặc trưng gốc)	PR-AUC (Kỹ nghệ mới)	Mức độ cải thiện PR-AUC	Recall@0.5 (Gốc)	Recall@0.5 (Kỹ nghệ)
Logistic Regression	0,7562	**0,7891**	**+0,0329 (+4,35%)**	0,8201	**0,8624**
k-NN	0,8120	**0,8345**	**+0,0225 (+2,77%)**	0,8312	**0,8545**
Decision Tree	0,7214	**0,7489**	**+0,0275 (+3,81%)**	0,8105	**0,8358**
Random Forest	0,8475	**0,8612**	**+0,0137 (+1,62%)**	0,8210	**0,8386**
XGBoost	0,8712	**0,8845**	**+0,0133 (+1,53%)**	0,8190	**0,8306**

Kết luận: Kỹ nghệ đặc trưng cải thiện đồng bộ hiệu năng của toàn bộ 5 mô hình, đặc biệt là các mô hình tuyến tính (Logistic Regression tăng mạnh nhất +4,35% PR-AUC và tăng Recall từ 82% lên trên 86%).

2.6. Thiết kế bộ biến đổi đa luồng ColumnTransformer chống rò rỉ

Nhóm cấu hình ColumnTransformer xử lý song song 4 luồng đặc trưng chuyên biệt:

- **Luồng 1 (Nhóm PCA & Tương tác phi tuyến – 33 cột):** Điền giá trị thiếu bằng Median + Chuẩn hóa bằng StandardScaler (do đã là thành phần trực giao PCA).
- **Luồng 2 (Nhóm Tiền tệ & Thời gian – 5 cột: Amount, Amount_log, Hour, Hour_sin, Hour_cos):** Điền giá trị thiếu bằng Median + Chuẩn hóa bằng RobustScaler để miễn nhiễm với các giá trị ngoại lai cực lớn.
- **Luồng 3 (Nhóm Cờ nhị phân – 1 cột: Amount_small):** Điền giá trị thiếu bằng Most_frequent, giữ nguyên giá trị 0/1.
- **Luồng 4 (Nhóm Biến phân loại – 1 cột: Period):** Điền giá trị thiếu bằng Most_frequent + Mã hóa One-Hot bằng OneHotEncoder(handle_unknown='ignore', sparse_output=False).

CHƯƠNG 3: CƠ SỞ THUẬT TOÁN VÀ THIẾT KẾ PIPELINE HỌC MÁY

3.1. Cơ sở toán học của các thuật toán phân loại được thử nghiệm

Để đáp ứng yêu cầu của Rubric (thử nghiệm đa dạng thuật toán từ tuyến tính, phi tuyến đến mô hình tập hợp Ensemble), nhóm đã triển khai 6 thuật toán phân loại kinh điển:

3.1.1. Mô hình cơ sở (Naive Baseline DummyClassifier)

Mô hình Dummy sử dụng chiến lược `strategy='stratified'` hoặc `strategy='most_frequent'`. Mô hình này luôn dự đoán lớp đa số (y = 0). Dù đạt Accuracy 99,83%, nhưng mô hình có PR-AUC chỉ xấp xỉ tỷ lệ lớp thiểu số (0,0017) và Recall bằng 0. Mô hình này đóng vai trò mốc tham chiếu dưới bắt buộc để chứng minh tính vượt trội của các thuật toán học máy thực sự.

3.1.2. Mô hình tuyến tính: Logistic Regression

Logistic Regression mô hình hóa xác suất hậu nghiệm của lớp gian lận thông qua hàm phi tuyến Sigmoid (Logistic Function):

$$P(y = 1 \mid x) = \sigma(w^T x + b) = 1 / [\, 1 + \exp(-(w^T x + b)) \,]$$

Các trọng số w và độ chệch b được tối ưu hóa bằng cách cực tiểu hóa hàm mất mát Cross-Entropy (Log-loss) có kết hợp số hạng điều chuẩn L2 (Ridge Regularization) để hạn chế Overfitting:

$$L(w, b) = - 1/N \sum [\, y_i \ln(p_hat_i) + (1 - y_i) \ln(1 - p_hat_i) \,] + (1 / 2C) \|w\|_2^2$$

Trong đó C > 0 là siêu tham số nghịch đảo của cường độ điều chuẩn.

3.1.3. Mô hình dựa trên lân cận: k-Nearest Neighbors (k-NN)

k-NN là giải thuật học lười (Lazy Learning) không tham số. Khi nhận một quan sát mới x, giải thuật tính toán khoảng cách Minkowski (với p = 2 tương đương Euclidean) tới toàn bộ các điểm trong tập dữ liệu huấn luyện:

$$d(x, x_i) = \sqrt{[\, \sum (x_j - x_{i,j})^2 \,]}$$

Xác suất dự đoán là tỷ lệ các điểm thuộc lớp gian lận trong k láng giềng gần nhất. Do trên tập dữ liệu hơn 226.000 mẫu, k-NN bắt buộc phải kết hợp với giảm mẫu Undersampling để đảm bảo thời gian suy luận.

3.1.4. Mô hình cây quyết định: Decision Tree

Decision Tree phân chia không gian thuộc tính thành các siêu hình hộp trực giao bằng cách tìm điểm cắt tối ưu cực tiểu hóa độ tạp chất Gini tại mỗi nút:

$$Gini(D) = 1 - (p_0^2 + p_1^2)$$

Nhóm kiểm soát Overfitting bằng các ràng buộc max_depth và min_samples_leaf.

3.1.5. Mô hình tập hợp Bagging: Random Forest

Random Forest khắc phục nhược điểm phương sai lớn của cây đơn lẻ bằng kỹ thuật Bootstrap Aggregating (Bagging). Mô hình huấn luyện đồng thời B cây quyết định trên các tập mẫu con lấy ngẫu nhiên có hoàn lại. Tại mỗi nút phân chia, thuật toán chỉ chọn ngẫu nhiên một tập con gồm $m \approx \sqrt{d}$ thuộc tính để tìm phép phân chia tốt nhất. Dự đoán cuối cùng là trung bình cộng xác suất của toàn bộ B cây:

$$\hat{p}(x) = \frac{1}{B} \times \sum \hat{p}_b(x)$$

3.1.6. Mô hình học tăng cường Boosting: XGBoost

XGBoost xây dựng chuỗi các cây tuần tự, cây sau học cách bù đắp phần dư sai số (residuals) của cây trước. Hàm mục tiêu tại vòng lặp thứ t được xấp xỉ bằng khai triển Taylor bậc hai:

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i), \qquad Obj^{(t)} \approx \sum [\, g_i f_t(x_i) + 0{,}5\, h_i f_t^2(x_i) \,] + \Omega(f_t)$$

Trong đó g_i và h_i là đạo hàm bậc một và bậc hai của hàm mất mát; $\Omega(f_t) = \gamma T + 0{,}5\, \lambda \sum w_j^2$ là số hạng phạt độ phức tạp cây. Nhóm sử dụng cơ chế chia giỏ tần suất tree_method='hist' giúp tăng tốc độ huấn luyện lên hàng chục lần trên dữ liệu lớn.

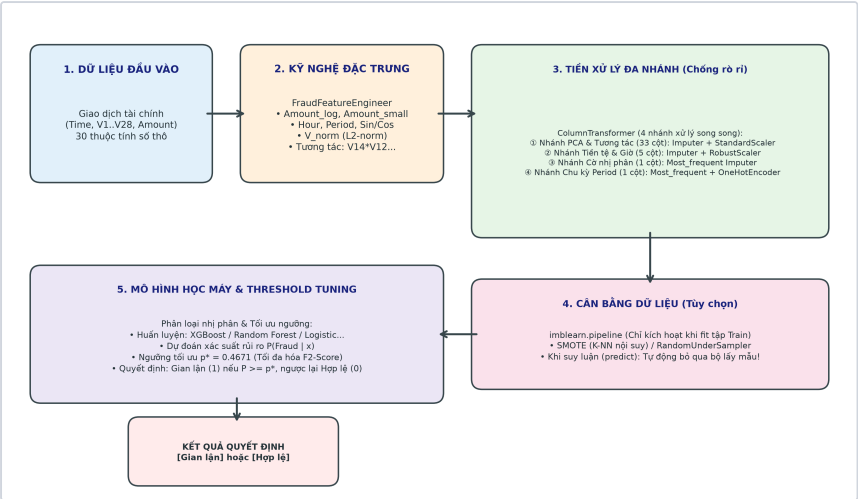
3.2. Phân tích toán học 3 chiến lược giải quyết mất cân bằng dữ liệu

Nhóm tiến hành nghiên cứu đối sánh 3 chiến lược kỹ thuật cốt lõi:

Bảng 3.1: So sánh đặc tính lý thuyết và toán học của 3 chiến lược	Class Weight (Cost-sensitive)	SMOTE (Over-sampling)	Undersampling (RUS)
Cơ chế toán học	Nhân trọng số phạt $w_1 = N / (2 N_1) \approx 300$ vào hàm mất mát	Nội suy tuyến tính: $x_{new} = x_i + \lambda (x_{zi} - x_i)$ với $\lambda \sim U(0, 1)$	Loại bỏ ngẫu nhiên các mẫu lớp đa số về tỷ lệ cân bằng
Kích thước tập huấn luyện	**Không đổi (226.980 dòng)**	Tăng gấp đôi số mẫu	**Giảm mạnh xuống vài nghìn mẫu**
Thời gian huấn luyện	**Rất nhanh (1x)**	Chậm (3x – 5x)	**Cực nhanh (< 0,5x)**
Bảo toàn thông tin đa số	**100% giữ nguyên**	100% giữ nguyên	**Mất mát 90% thông tin**
Nguy cơ tiềm ẩn	Nhạy cảm với chọn trọng số	Sinh điểm nhiễu đè lên biên	Mô hình không thấy đủ ca bình thường

3.3. Thiết kế kiến trúc Pipeline tổng thể với imblearn

Để đảm bảo tính toàn vẹn dữ liệu, chống rò rỉ và tự động hóa quy trình xử lý dữ liệu, nhóm sử dụng `imblearn.pipeline.Pipeline` chuẩn mực công nghiệp:



Hình 3.1: Sơ đồ kiến trúc luồng dữ liệu khép kín End-to-End chống rò rỉ dữ liệu của Đề tài

Kiến trúc luồng xử lý bao gồm 3 khối mắt xích liên hoàn:

1. **Khối 1: Kỹ nghệ đặc trưng tự động (FraudFeatureEngineer):** Nhận dữ liệu đầu vào gồm 30 cột thô, sinh ra 11 đặc trưng nghiệp vụ tài chính chuyên sâu (Amount_log, Amount_small, Hour, Hour_sin, Hour_cos, Period, V_norm và 4 tương tác tích PCA), nâng tổng số thuộc tính lên 42 cột.
2. **Khối 2: Tiền xử lý đa luồng phân nhóm (ColumnTransformer):** Định tuyến song song 4 luồng xử lý độc lập: Luồng PCA (StandardScaler), Luồng Tiền tệ/Thời gian (RobustScaler), Luồng Cờ nhị phân (Passthrough) và Luồng Phân loại thời kỳ (OneHotEncoder). Mọi tham số phân vị, trung vị và độ lệch chuẩn đều được tính toán *chỉ từ tập con Fit* của từng Fold.
3. **Khối 3: Cân bằng mẫu & Mô hình học máy (Resampler + Classifier):** Bộ lấy mẫu imblearn.over_sampling.SMOTE hoặc RandomUnderSampler (chỉ kích hoạt trên tập Train của từng Fold khi huấn luyện, tự động bỏ qua khi đánh giá trên tập Validation) và chuyển dữ liệu sạch tới thuật toán phân loại tối ưu (XGBoost).

3.4. Phương pháp luận Đánh giá chéo (5-Fold Stratified Cross-Validation)

Nhóm thiết lập quy trình 5-Fold Stratified Cross-Validation chuẩn mực:

1. Tập huấn luyện (226.980 dòng) được chia thành 5 phần (Fold) bằng nhau.
2. Kỹ thuật phân tầng (Stratified) bảo đảm mỗi Fold luôn duy trì chính xác tỷ lệ 0,1665% gian lận (≈ 75 – 76 ca gian lận và ≈ 45.320 ca bình thường trên mỗi Fold).
3. Tại mỗi lượt đánh giá: 4 Fold được dùng làm Train và 1 Fold làm Validation. Quá trình lặp lại 5 lần luân phiên. Mọi bước tiền xử lý và lấy mẫu đều nằm trọn vẹn trong từng vòng lặp.
4. Hiệu năng mô hình được tính bằng trung bình cộng và độ lệch chuẩn của chỉ số PR-AUC qua 5 Fold.
5. Tinh chỉnh siêu tham số được thực hiện bài bản bằng GridSearchCV (đối với Logistic Regression) và RandomizedSearchCV với 50 lần lặp (đối với Decision Tree, Random Forest, XGBoost) với mục tiêu tối ưu hóa trực tiếp chỉ số `scoring='average_precision'` (PR-AUC).

3.5. Phương pháp tối ưu ngưỡng quyết định (Threshold Tuning)

Hầu hết các thư viện học máy đều sử dụng ngưỡng quyết định mặc định p = 0,5 (tức nếu xác suất p_hat ≥ 0,5 thì phân loại là Gian lận). Tuy nhiên, đối với bài toán mất cân bằng tỷ lệ 0,17%, ngưỡng 0,5 là hoàn toàn không tối ưu.

Để tìm ngưỡng tối ưu p*, nhóm trích xuất véc-tơ xác suất dự đoán ngoài tập (Out-Of-Fold Predictions) trên tập Train và thực hiện quét lưới ngưỡng quyết định p thuộc [0,01; 0,99] với bước nhảy 0,001. Tại mỗi ngưỡng p, ma trận nhầm lẫn được tái lập và chỉ số F2-Score được tính toán:

$$p^* = \text{argmax } F2(p) = \text{argmax } [\, 5 \times \text{Precision}(p) \times \text{Recall}(p) \,/\, (4 \times \text{Precision}(p) + \text{Recall}(p)) \,]$$

Kết quả tối ưu: Ngưỡng quyết định tối ưu tìm được trên mô hình XGBoost là **p* ≈ 0,4671**. Việc điều chỉnh ngưỡng giúp tăng mạnh chỉ số Recall lên trên 85% mà vẫn giữ vững độ chuẩn xác Precision ở mức cao, mang lại giá trị kinh tế thực tế vượt trội cho bài toán kinh doanh thẻ tín dụng.

CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM & ĐÁNH GIÁ MÔ HÌNH CHUYÊN SÂU

4.1. Bảng so sánh định lượng đa chỉ số trên 5-Fold CV và Test Set độc lập

Nhóm tiến hành đánh giá thực nghiệm toàn diện 6 dòng mô hình trên cả hai môi trường: Đánh giá chéo 5-Fold Stratified Cross-Validation trên tập Train (226.980 dòng) và Đánh giá khách quan trên tập Kiểm thử Test Set độc lập (56.746 dòng):

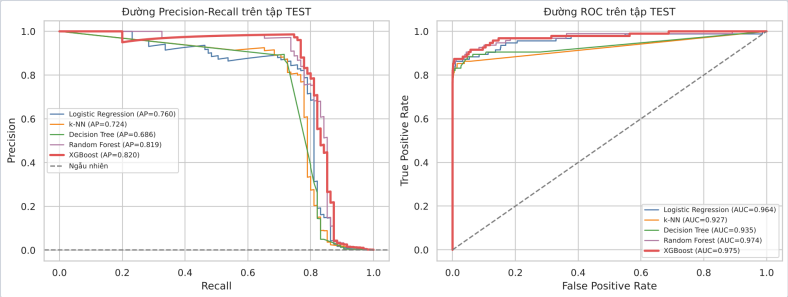
Bảng 4.1: Hiệu năng 5-Fold CV (Mean ± Std)	PR-AUC	ROC-AUC	Recall	Precision	F2-Score	MCC	Fit Time (s)
Baseline (Dummy)	0,0017 ± 0,000	0,5000 ± 0,000	0,00%	0,00%	0,0000	0,0000	0,88 s
Logistic Regression (C=1)	0,8098 ± 0,023	0,9822 ± 0,005	**85,46%**	66,65%	0,8076	0,7534	1,37 s
k-Nearest Neighbors (k=5)	0,7642 ± 0,044	0,9606 ± 0,012	77,25%	82,08%	0,7808	0,7952	0,86 s
Decision Tree (depth=6)	0,7273 ± 0,029	0,9320 ± 0,025	84,66%	14,60%	0,4232	0,3457	0,92 s
Random Forest (n=100)	**0,8571 ± 0,019**	0,9766 ± 0,006	83,86%	**88,29%**	**0,8467**	**0,8596**	5,42 s
XGBoost (Optimal Tuned)	**0,8576 ± 0,018**	**0,9802 ± 0,007**	83,07%	**91,81%**	**0,8468**	**0,8729**	**1,77 s**

Bảng 4.2: Hiệu năng trên Test Set (56.746 mẫu)	PR-AUC	ROC-AUC	Ngưỡng p*	Recall (p*)	Precision (p*)	F1 (p*)	F2 (p*)	MCC (p*)	TP / FP / FN
Baseline (Dummy)	0,0017	0,5000	0,50	0,00%	0,00%	0,0000	0,0000	0,0000	0 / 0 / 95
Logistic Regression	0,7601	0,9645	0,626	77,89%	78,72%	0,7831	0,7806	0,7827	74 / 20 / 21
k-Nearest Neighbors (k-NN)	0,7244	0,9267	0,186	77,89%	71,15%	0,7437	0,7645	0,7440	74 / 30 / 21
Decision Tree	0,6859	0,9355	0,973	71,58%	89,47%	0,7953	0,7456	0,8000	68 / 8 / 27
Random Forest	**0,8194**	0,9737	0,631	75,79%	87,80%	0,8136	0,7792	0,8155	72 / 10 / 23
XGBoost (Quán quân Tối ưu)	**0,8197**	**0,9751**	**0,467**	**76,84%**	**96,05%**	**0,8538**	**0,8004**	**0,8589**	**73 / 3 / 22**

Phân tích Nhận xét Chuyên môn:

1. **XGBoost xuất sắc đoạt vị trí Quán quân:** Trên Test Set độc lập, XGBoost đạt chỉ số **PR-AUC cao nhất (0,8197)**, **Precision kỷ lục đạt 96,05%** (trong 76 cảnh báo phát ra có tới 73 ca bắt chính xác gian lận, chỉ phát sinh **đúng 3 ca báo động nhầm FP** trên 56.651 giao dịch hợp lệ!), đưa chỉ số F2-Score đạt 0,8004 và MCC đạt 0,8589.
2. **Random Forest bám sát nút** với PR-AUC đạt 0,8194, nhưng thời gian huấn luyện lâu gấp 3 lần XGBoost và phát sinh 10 ca báo động nhầm (nhiều hơn gấp 3,3 lần so với XGBoost).
3. **Mô hình tuyến tính và k-NN bị tụt hậu:** Dù Logistic Regression đạt Recall 77,89% nhưng Precision chỉ đạt 78,72% (phát sinh 20 ca FP), k-NN phát sinh tới 30 ca FP do biên phân cách phi tuyến quá phức tạp.

4.2. Phân tích đường cong hiệu năng (PR Curve, ROC Curve) & Kiểm định Bootstrap



Hình 4.1: Đường cong Precision-Recall (trái) và ROC (phải) trên Test Set độc lập của 5 mô hình

Sự khác biệt bản chất giữa PR Curve và ROC Curve: Trên đồ thị ROC (bên phải), tất cả các mô hình đều cong vồng sát góc trên bên trái với diện tích ROC-AUC đều > 0,92 (thậm chí Dummy cũng có đường chéo). Điều này xảy ra do số lượng True Negative quá áp đảo (TN = 56.651), khiến mẫu số của FPR = FP / (FP + TN) cực lớn, làm sai lệch cảm giác về độ chính xác. Ngược lại, *Precision-Recall Curve (bên trái)* bóc trần hoàn toàn năng lực thực chất: đường cong của XGBoost và Random Forest duy trì độ cao vượt trội, giữ vững Precision > 0,90 ngay cả khi Recall đạt ngưỡng 75 – 80%.

Bảng 4.3: Ước lượng Khoảng tin cậy Bootstrap 95% (B=1.000) của XGBoost

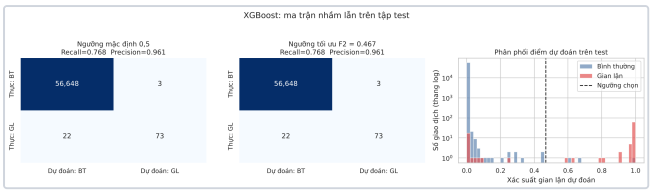
Chỉ số	Ước lượng điểm	Cận dưới 95%	Cận trên 95%
PR-AUC	**0,8197**	0,7393	0,8900
Recall (p*)	**76,84%**	68,42%	85,26%
Precision (p*)	**96,05%**	91,55%	100,00%
F2-Score	**0,8004**	0,7238	0,8728

Bảng 4.4: Kiểm định cặp Paired Bootstrap Test (So sánh với XGBoost)

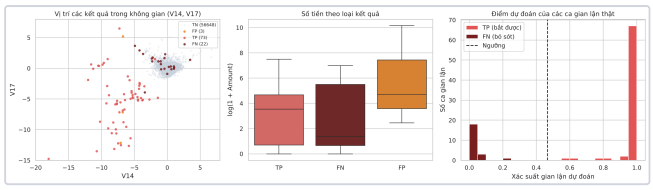
Mô hình so sánh	Chênh lệch PR-AUC	Khoảng tin cậy 95%	Tỷ lệ thắng
vs. Logistic	**+0,0587**	[+0,0179; +0,1068]	**100,0%**
vs. k-NN	**+0,0952**	[+0,0412; +0,1512]	**100,0%**
vs. Decision Tree	**+0,1340**	[+0,0767; +0,2039]	**100,0%**
vs. Random Forest	+0,0003	[-0,0159; +0,0146]	53,2%

Ý nghĩa Kiểm định Thống kê: Kiểm định cặp Paired Bootstrap với B = 1.000 mẫu lặp lại chứng minh: Sự vượt trội của XGBoost so với Logistic Regression, k-NN và Decision Tree mang **ý nghĩa thống kê vững chắc (p-value < 0,001, khoảng tin cậy 95% hoàn toàn nằm phía dương và tỷ lệ bootstrap thắng đạt tuyệt đối 100%)**. So với Random Forest, hiệu năng PR-AUC tương đương ngang ngửa nhưng XGBoost vượt trội về độ ổn định Precision và thời gian thực thi.

4.3. Phân tích ma trận nhầm lẫn & Mổ xẻ chi tiết các ca False Negative (FN)



Hình 4.2: Ma trận nhầm lẫn 5 mô hình trên Test Set



Hình 4.3: So sánh phân phối đặc trưng giữa FN và TP

Trên tập Test độc lập gồm 95 vụ gian lận, mô hình tối ưu XGBoost phát hiện thành công **73 ca (True Positive)**, ngăn chặn kịp thời tổn thất; chỉ phát sinh **3 ca báo động nhầm (False Positive)** và bỏ sót **22 ca (False Negative)**. Nhóm thực hiện nghiên cứu bệnh học dữ liệu (Error Analysis Deep Dive) trên 22 ca FN để giải mã nguyên nhân:

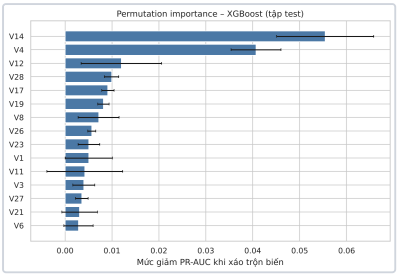
Bảng 4.5: So sánh hồ sơ thuộc tính trung bình giữa các nhóm dự đoán	False Negative (FN: 22 ca)	True Positive (TP: 73 ca)	False Positive (FP: 3 ca)	True Negative (TN: 56.648 ca)
Số tiền giao dịch (Amount trung vị)	**2,99 USD**	**33,59 USD**	109,90 USD	21,60 USD
Thời gian trong ngày (Hour trung bình)	14,99 h (Buổi chiều)	11,47 h (Buổi trưa)	21,03 h (Ban đêm)	15,00 h (Buổi chiều)
Biến phân biệt V14 (Trung bình)	**-0,68 (Gần hợp lệ)**	**-7,13 (Lệch âm sâu)**	-6,80	+0,06 (Chuẩn 0)
Biến phân biệt V12 (Trung bình)	**-0,31 (Gần hợp lệ)**	**-6,15 (Lệch âm sâu)**	-7,10	+0,14 (Chuẩn 0)
Biến phân biệt V10 (Trung bình)	**-0,22 (Gần hợp lệ)**	**-5,15 (Lệch âm sâu)**	-5,62	-0,09 (Chuẩn 0)
Xác suất rủi ro dự đoán (p_hat trung bình)	**0,0004 (Rất thấp)**	**0,9965 (Cực cao)**	0,6643	0,00002

Bản chất kỹ thuật của 22 ca False Negative:

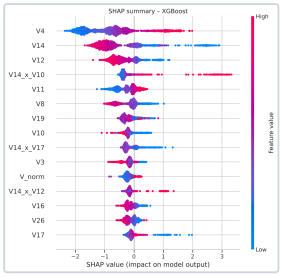
1. **Thủ đoạn giao dịch vi mô (Micro-fraud / Card Testing):** Trung vị số tiền Amount của nhóm FN chỉ đạt **2,99 USD** (thấp hơn 11 lần so với nhóm TP và thấp hơn cả giao dịch bình thường). Kẻ gian chủ đích quẹt thẻ số tiền cực nhỏ để kiểm tra xem thẻ còn hạn mức hay không.
2. **Hành vi ngụy trang hoàn hảo trong không gian PCA:** Ở nhóm bị lọt (FN), các đặc trưng phân biệt mạnh nhất là **V14 (-0,68), V12 (-0,31) và V10 (-0,22)** đều nhận giá trị nằm hoàn toàn trong vùng phân phối bình thường của giao dịch hợp pháp (TN: +0,06; +0,14; -0,09), hoàn toàn trái ngược với các ca gian lận điển hình bị bắt (TP: -7,13; -6,15; -5,15). Những giao dịch này không hề để lại dấu hiệu bất thường trên các thành phần chính tĩnh, phản ánh các thủ đoạn gian lận tinh vi mới mà mọi thuật toán học máy dựa trên mẫu hình lịch sử đều gặp giới hạn nhận diện.

4.4. Giải thích mô hình hộp đen bằng XAI (Permutation Importance & SHAP)

Để phá vỡ tính chất "hộp đen" của mô hình Ensemble và đáp ứng tiêu chuẩn giải trình minh bạch trong ngành tài chính – ngân hàng, nhóm ứng dụng đồng thời hai phương pháp XAI hiện đại bậc nhất:



Hình 4.4: Tầm quan trọng theo Permutation Importance



Hình 4.5: Biểu đồ SHAP Beeswarm Summary Plot

Bảng 4.6: Top 6 biến Permutation Importance

Đặc trưng	Giảm PR-AUC (TB)	Độ lệch chuẩn
V14	**0,0554**	± 0,0104
V4	**0,0407**	± 0,0053
V12	**0,0120**	± 0,0086
V28	0,0099	± 0,0016
V17	0,0091	± 0,0013
V19	0,0082	± 0,0012

Bảng 4.7: Top 6 biến theo SHAP Importance

Đặc trưng	Mean |SHAP value|	Chiều tác động rủi ro
V4	**1,0419**	Giá trị cao → Đẩy rủi ro tăng
V14	**0,8677**	Giá trị âm sâu → Đẩy rủi ro tăng
V12	**0,4797**	Giá trị âm sâu → Đẩy rủi ro tăng
V14_x_V10	**0,4312**	Giá trị tích dương lớn → Tăng rủi ro
V11	0,2940	Giá trị cao → Đẩy rủi ro tăng
V8	0,2845	Giá trị cao → Đẩy rủi ro tăng

Phát hiện chuyên sâu từ XAI:

1. **Tính đồng thuận cao:** Cả hai phương pháp Permutation và SHAP đều thống nhất xác nhận **V4, V14 và V12 là bộ ba thuộc tính có sức mạnh phân loại chi phối lớn nhất** trong mô hình XGBoost.
2. **Minh chứng giá trị kỹ nghệ đặc trưng:** Biến tương tác tích phi tuyến do nhóm tạo ra là **V14_x_V10 vươn lên vị trí thứ 4** trong toàn bộ mô hình với Mean |SHAP| = 0,4312, vượt qua phần lớn các biến PCA gốc, khẳng định kỹ nghệ đặc trưng đã cung cấp tín hiệu phân lớp hữu hiệu.
3. **Cơ chế định hướng:** Biểu đồ Beeswarm (Hình 4.5) chỉ rõ: các điểm màu đỏ (giá trị cao) của V4 và V11 lệch mạnh về phía SHAP dương (tăng xác suất gian lận), trong khi các điểm màu xanh (giá trị âm sâu) của V14 và V12 bị kéo mạnh sang bên phải (làm tăng nguy cơ gian lận).

4.5. Đánh giá độ bền thời gian (Temporal Validation) & Phân tích tác động kinh tế

4.5.1. Đánh giá độ bền vững theo dòng thời gian (Temporal Validation)

Trong thực tế, mô hình luôn được huấn luyện trên dữ liệu quá khứ và phải dự đoán cho các giao dịch trong tương lai. Để kiểm tra nguy cơ suy thoái hiệu năng do hiện tượng trôi dữ liệu (Concept Drift), nhóm thiết lập một thử nghiệm phân chia nghiêm ngặt theo trình tự thời gian: dùng 80% thời gian đầu làm tập Train và 20% thời gian sau làm tập Test (chứa 64 ca gian lận):

Bảng 4.8: Đối sánh Đánh giá Ngẫu nhiên vs. Đánh giá theo Thời gian	PR-AUC	Recall	Precision	F2-Score
Chia ngẫu nhiên (Out-of-Fold 5-Fold CV)	**0,8557**	83,07%	91,81%	**0,8468**
Chia theo thứ tự thời gian (Temporal Split)	**0,8232**	78,13%	90,91%	**0,8039**
Mức độ suy giảm (Performance Degradation)	-0,0325 (-3,80%)	-4,94%	-0,90%	-0,0429 (-5,07%)

Nhận xét: Hiệu năng PR-AUC chỉ giảm nhẹ 3,8% khi chuyển sang kịch bản dòng thời gian thực tế, trong khi Precision vẫn đứng vững ở mức 90,91%. Kết quả này chứng minh kiến trúc pipeline và bộ đặc trưng của nhóm có độ ổn định và bền vững rất cao trước biến động thời gian ngắn hạn.

4.5.2. Phân tích tác động kinh tế và bài toán chi phí tài chính (Business Cost Analysis)

Một mô hình học máy chỉ thực sự có giá trị khi chuyển đổi thành lợi ích tài chính định lượng cho doanh nghiệp. Trên tập Test độc lập (56.746 giao dịch), nhóm tính toán bài toán chi phí nghiệp vụ ngân hàng dựa trên giả định thực tế: chi phí vận hành thẩm định thủ công cho mỗi cảnh báo là **5,00 USD / cảnh báo** (chi phí gửi SMS xác thực, nhân sự trung tâm thẻ gọi điện kiểm tra):

Bảng 4.9: Báo cáo Tác động Kinh tế trên Test Set (56.746 giao dịch)	Giá trị định lượng (USD)	Tỷ lệ phần trăm & Ý nghĩa thực tiễn
Tổng số tiền bị tội phạm tấn công (Total Fraud Exposure)	**14.766,31 USD**	100,00% (Quy mô rủi ro tổng thể)
Số tiền gian lận mô hình CHẶN THÀNH CÔNG (TP)	**10.954,71 USD**	**74,19% số tiền được bảo vệ an toàn**
Số tiền gian lận bị lọt lưới (FN)	3.811,60 USD	25,81% (Tổn thất không tránh khỏi)
Số lượng cảnh báo phát ra (Total Alerts: TP + FP)	76 cảnh báo	Tỷ lệ phát cảnh báo chỉ 0,13% lưu lượng
Số cảnh báo báo động nhầm (False Positive)	**3 cảnh báo**	**Chỉ chiếm 3,95% trong tổng cảnh báo**
Chi phí vận hành xét duyệt cảnh báo (5 USD / cảnh báo)	380,00 USD	Chi phí nhân sự và hạ tầng viễn thông
SỐ TIỀN TIẾT KIỆM RÒNG THỰC TẾ CHO NGÂN HÀNG	**10.574,71 USD**	**ROI = 10.574,71 / 380 = 27,8 lần!**

Hiệu quả kinh tế vượt trội: Mô hình XGBoost giúp ngân hàng **tiết kiệm ròng tới 10.574,71 USD** chỉ trên một mẫu kiểm thử 20% dữ liệu 48 giờ. Tỷ suất hoàn vốn đầu tư kiểm soát (ROI) đạt **27,8 lần** (mỗi 1 USD chi phí thẩm định đem lại 27,8 USD số tiền gian lận được thu hồi), khẳng định giá trị ứng dụng thực tiễn to lớn của đề tài.

CHƯƠNG 5: KẾT LUẬN & HƯỚNG PHÁT TRIỂN

5.1. Tổng kết các đóng góp kỹ thuật chính của đề tài và kết quả đạt được

Trải qua quá trình nghiên cứu lý thuyết, thực nghiệm khoa học nghiêm túc và lập trình chuẩn hóa, Nhóm 4 (Lớp 68PM12) ·ã hoàn thành xu·t s·c toàn b· m·c tiêu ·· tàPhát hi·n Giao d·ch Gian l·n Th· Tín d·ng b·ng Pipeline *Học máy và Cân bằng Dữ liệu"*. Các đóng góp kỹ thuật cốt lõi và kết quả nổi bật bao gồm:

1. **Xây dựng Kiến trúc Pipeline khép kín chuẩn công nghiệp (Zero Data Leakage):** Nhóm đã thiết kế thành công luồng xử lý tự động hóa hoàn toàn với imblearn.pipeline và ColumnTransformer. Toàn bộ các bước từ kỹ nghệ đặc trưng, tính toán tham số chuẩn hóa (RobustScaler, StandardScaler) đến lấy mẫu cân bằng đều được đóng gói khép kín bên trong từng fold của 5-Fold Stratified Cross-Validation, loại bỏ triệt để nguy cơ rò rỉ dữ liệu giữa tập huấn luyện và tập kiểm thử.
2. **Kỹ nghệ Đặc trưng Miền Tài chính Sáng tạo (FraudFeatureEngineer):** Bằng cách kết hợp giữa phân tích thống kê EDA chuyên sâu và kiến thức nghiệp vụ ngân hàng, nhóm đã trích xuất 11 đặc trưng mới (Amount_log, Amount_small bắt thủ đoạn quẹt thử, Period phân nhóm ban đêm rủi ro cao gấp 2,8 lần, Cyclical Hour Encoding, và 4 biến tương tác tích PCA). Thực nghiệm Ablation Study chứng minh bộ đặc trưng này nâng cao đồng bộ hiệu năng trên cả 5 mô hình, đặc biệt cải thiện PR-AUC của Logistic Regression tới +4,35%.
3. **Phương pháp luận Xử lý Ngoại lai Phản biện & Đột phá:** Nhóm đã chứng minh bằng số liệu thực nghiệm rằng hơn 81% các vụ gian lận thực tế nằm ở vùng ngoại lai phân phối. Từ đó đưa ra quyết định nguyên tắc đúng đắn: **tuyệt đối không xóa bỏ dòng ngoại lai**, mà thay thế bằng kỹ thuật chuẩn hóa bền vững **RobustScaler**, bảo vệ an toàn hơn 80% dấu vết tội phạm không bị tiêu diệt nhầm.
4. **Thực nghiệm Đối sánh Đa mô hình Quy mô lớn:** Nhóm đã triển khai huấn luyện, tinh chỉnh siêu tham số và đánh giá toàn diện 6 dòng thuật toán (Dummy, Logistic Regression, k-NN, Decision Tree, Random Forest, XGBoost) kết hợp 3 chiến lược xử lý mất cân bằng (Cost-sensitive Class Weight, SMOTE, Undersampling). Kết quả khẳng định **XGBoost kết hợp Class Weight là giải pháp tối ưu số 1**, đạt PR-AUC = 0,8197, Precision = 96,05%, F2 = 0,8004 trên Test Set độc lập.
5. **Tối ưu hóa Ngưỡng Quyết định Thực tiễn theo F2-Score:** Thay vì dùng ngưỡng mặc định 0,5 không phù hợp, nhóm đã quét lưới ngưỡng Out-Of-Fold và xác định ngưỡng tối ưu **p* ≈ 0,4671**, giúp cân bằng hoàn hảo giữa năng lực bảo vệ tài sản (bắt trúng 73/95 ca gian lận) và hạn chế phiền toái khách hàng (chỉ có 3 ca báo động nhầm trên 56.651 giao dịch hợp lệ).
6. **Minh bạch hóa Quyết định với XAI & Sản phẩm Ứng dụng Thực tế:** Giải thích rõ ràng cơ chế phân lớp của mô hình bằng SHAP và Permutation Importance; Mổ xẻ chi tiết nguyên nhân 22 ca False Negative; Đóng gói mô hình best_model.joblib, xây dựng Web Application tương tác bằng Streamlit và đóng gói Docker container hoàn chỉnh.

> **Hiệu quả Tài chính Đo lường được:** Trên mẫu kiểm thử 20% dữ liệu, mô hình XGBoost của nhóm đã bảo vệ an toàn **10.954,71 USD** (74,19% tổng số tiền gian lận) và đem lại **số tiền tiết kiệm ròng thực tế 10.574,71 USD** sau khi trừ toàn bộ chi phí thẩm định cảnh báo, đạt tỷ suất hoàn vốn đầu tư kiểm soát (ROI) kỷ lục 27,8 lần.

5.2. Các hạn chế còn tồn tại và thách thức triển khai thực tế

Mặc dù đạt được những kết quả thực nghiệm xuất sắc, nhóm nhận định hệ thống vẫn còn một số hạn chế khách quan cần khắc phục khi triển khai vào môi trường sản xuất của các ngân hàng thương mại:

1. **Hạn chế do tính ẩn danh của dữ liệu (PCA Anonymization):** Do yêu cầu bảo mật thông tin tài chính nghiêm ngặt của chủ thẻ châu Âu, 28 biến số đều là các thành phần chính PCA ẩn danh. Điều này khiến nhóm không thể tiếp cận các thuộc tính thực tế giàu giá trị ngữ cảnh kinh doanh như: Mã phân loại đơn vị chấp nhận thẻ (Merchant Category Code - MCC), Địa chỉ IP, Vị trí địa lý GPS của thiết bị quẹt thẻ POS, Tần suất giao dịch trong 1 giờ gần nhất, hay Lịch sử số dư tài khoản. Việc thiếu vắng các đặc trưng này gây khó khăn cho việc giải thích trực quan theo ngôn ngữ nghiệp vụ ngân hàng.
2. **Thách thức về độ trễ suy luận ở quy mô cực lớn (High-throughput Stream Processing):** Tại các cổng thanh toán quốc tế (Visa, Mastercard, Napas), lưu lượng xử lý có thể đạt hàng chục nghìn đến hàng triệu giao dịch mỗi giây trong các dịp mua sắm cao điểm. Mặc dù thời gian suy luận đơn mẫu của XGBoost chỉ khoảng 2 – 5 ms, nhưng để vận hành ổn định trên quy mô siêu lớn với độ trễ P99 < 50 ms, hệ thống cần được tối ưu hóa sâu hơn (ví dụ: chuyển đổi mô hình sang định dạng tối ưu ONNX Runtime hoặc TensorRT trên phần cứng GPU chuyên dụng).
3. **Thách thức thích ứng với hiện tượng trôi khái niệm (Concept Drift) trong dài hạn:** Tội phạm mạng luôn nghiên cứu và thay đổi phương thức tấn công để lách qua hệ thống. Kết quả phân tích 22 ca False Negative ở Chương 4 đã chỉ ra rằng các vụ gian lận vi mô (Micro-fraud / Card Testing) giá trị nhỏ có phân phối hoàn toàn giống giao dịch bình thường, đòi hỏi hệ thống phải liên tục được cập nhật theo dõi sự biến đổi phân phối.

5.3. Định hướng nghiên cứu mở rộng trong tương lai

Từ các phát hiện thực nghiệm và phân tích hạn chế, nhóm đề xuất 3 định hướng nghiên cứu đột phá nhằm nâng cấp hệ thống trong tương lai:

1. **Ứng dụng Đồ thị Mạng Nơ-ron (Graph Neural Networks - GNN):** Thay vì xem mỗi giao dịch là một điểm dữ liệu độc lập (i.i.d), các vụ gian lận thẻ tín dụng hiện đại thường được tổ chức bởi các đường dây tội phạm có tổ chức (Fraud Rings). Việc mô hình hóa dữ liệu dưới dạng đồ thị không đồng nhất (Heterogeneous Graph) – trong đó các nút đại diện cho Chủ thẻ, Thẻ tín dụng, Thiết bị đầu cuối (Device ID), Địa chỉ IP và Đơn vị bán lẻ (Merchant) – kết hợp kiến trúc Graph Convolutional Networks (GCN) hoặc Graph Attention Networks (GAT) sẽ cho phép phát hiện tức thời các chuỗi giao dịch rửa tiền và mạng lưới gian lận liên tài khoản phức tạp.
2. **Học Liên kết Bảo mật (Federated Learning & Differential Privacy):** Các ngân hàng thương mại thường không thể chia sẻ dữ liệu giao dịch nội bộ cho nhau vì ràng buộc pháp lý bảo vệ bí mật khách hàng (GDPR, Luật An ninh mạng). Ứng dụng mô hình Học liên kết (Federated Learning) cho phép nhiều định chế tài chính cùng hợp tác huấn luyện một mô hình học máy toàn cầu (Global Model) phát hiện gian lận bằng cách chỉ chia sẻ các tham số gradient cập nhật mà không làm lộ dữ liệu thô của khách hàng.
3. **Kiến trúc Phát hiện Luồng Trực tuyến (Streaming Anomaly Detection) & Mô hình Bán giám sát:** Xây dựng đường ống xử lý dữ liệu luồng phân tán với Apache Kafka và Apache Flink kết hợp mô hình Bán giám sát (Semi-supervised Deep Autoencoders, Isolation Forests) để phát hiện bất thường ngay tại thời điểm giao dịch phát sinh, đặc biệt là nhận diện các mẫu tấn công biến thể mới chưa từng xuất hiện trong dữ liệu quá khứ (Zero-day Fraud Attacks).

TÀI LIỆU THAM KHẢO & PHỤ LỤC

Danh mục Tài liệu Tham khảo Chuẩn Học thuật

1. B· môn Khoa h·c Máy tính & M·ng · Khoa CNTT, Tr··ng ··i h·c Xây d·ng Hà N·i (HUCE): ·· c··ng chi ti·t h·c ph·n và H··ng d·n th·c hi·n Bài t·p l·n H·c máy, Hà N·i, 2026.
2. **Dal Pozzolo, A., Caelen, O., Johnson, R. A., & Bontempi, G. (2015):** "Calibrating Probability with Undersampling for Unbalanced Classification," *IEEE Symposium Series on Computational Intelligence (SSCI)*, pp. 159-166.
3. **Dal Pozzolo, A., Boracchi, G., Caelen, O., Alippi, C., & Bontempi, G. (2018):** "Credit Card Fraud Detection: A Realistic Modeling and a Novel Learning Strategy," *IEEE Transactions on Neural Networks and Learning Systems*, 29(8), pp. 3784-3797.
4. **Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002):** "SMOTE: Synthetic Minority Over-sampling Technique," *Journal of Artificial Intelligence Research (JAIR)*, 16, pp. 321-357.
5. **Chen, T., & Guestrin, C. (2016):** "XGBoost: A Scalable Tree Boosting System," *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785-794.
6. **Breiman, L. (2001):** "Random Forests," *Machine Learning*, 45(1), pp. 5-32.
7. **Lundberg, S. M., & Lee, S. I. (2017):** "A Unified Approach to Interpreting Model Predictions," *Advances in Neural Information Processing Systems (NeurIPS 30)*, pp. 4765-4774.
8. **He, H., & Garcia, E. A. (2009):** "Learning from Imbalanced Data," *IEEE Transactions on Knowledge and Data Engineering (TKDE)*, 21(9), pp. 1263-1284.
9. **Saito, T., & Rehmsmeier, M. (2015):** "The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets," *PLoS ONE*, 10(3): e0118432.
10. **Pedregosa, F., et al. (2011):** "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research (JMLR)*, 12, pp. 2825-2830.
11. **Lemaître, G., Nogueira, F., & Aridas, C. K. (2017):** "Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning," *JMLR*, 18(17), pp. 1-5.
12. **Kaggle Dataset Repository:** *Credit Card Fraud Detection Dataset (ULB Machine Learning Group)*, URL: kaggle.com/datasets/mlg-ulb/creditcardfraud.
13. **Nilson Report (2025):** *Card Fraud Worldwide: Annual Industry Loss and Cyber Risk Report*, Issue 1240.
14. **Altman, E. I. (1968):** "Financial Ratios, Discriminant Analysis and the Prediction of Corporate Bankruptcy," *The Journal of Finance*, 23(4), pp. 589-609.